Laporan Tugas Besar 1

IF3170 Inteligensi Artifisial

Optimasi Pengisian Paket pada Truk Peti Kemas dengan Algoritma Local Search

Tahun Akademik 2026–2027



Disusun oleh:

Kelompok 37

Samuelson Dharmawan Tanuraharja – 13524001
Nicholas Wise Saragih Sumbayak – 13524037
Neswa Eka Anggara – 13524136

Laboratorium Inteligensi Artifisial
Program Studi Teknik Informatika
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Daftar Isi

1 Pendahuluan **3**
1.1 Latar Belakang . . . 3
1.2 Rumusan Persoalan dan Tujuan . . . 3
1.3 Entitas dan Atribut . . . 4
1.4 Ketentuan Representasi . . . 4
1.5 Batasan Persoalan . . . 5
1.6 Fungsi Objektif . . . 5

2 Dasar Teori **6**
2.1 Optimasi dan *Local Search* . . . 6
2.2 *State*, *Neighbor*, dan *Search Landscape* . . . 6
2.3 *Hill Climbing* . . . 7
2.4 *Simulated Annealing* . . . 8
2.5 *Genetic Algorithm* . . . 9

3 Pembahasan dan Implementasi **10**
3.1 Arsitektur Aplikasi . . . 10
3.1.1 Struktur Aplikasi . . . 10
3.1.2 Tech Stack . . . 11
3.2 Pemodelan Problem dan Constraint . . . 11
3.2.1 Data Problem . . . 11
3.2.2 Representasi State dan Orientasi . . . 13
3.2.3 Validasi Constraint . . . 13
3.2.4 Objective Function . . . 15
3.3 Implementasi Algoritma *Local Search* . . . 16
3.3.1 Inisialisasi State dan Pembangkitan Neighbor . . . 16
3.3.2 Hill Climbing . . . 16
3.3.3 Simulated Annealing . . . 19
3.3.4 Genetic Algorithm . . . 19

4 Eksperimen dan Analisis **21**
4.1 Rancangan Eksperimen . . . 21
4.1.1 Data Uji dan Lingkungan Eksperimen . . . 21
4.1.2 Konfigurasi Parameter dan Pengulangan Eksperimen . . . 21
4.2 Hasil Eksperimen dan Visualisasi Program . . . 22
4.2.1 Hill Climbing . . . 22
4.2.2 Simulated Annealing . . . 23
4.2.3 Genetic Algorithm . . . 24
4.3 Analisis Eksperimen . . . 24
4.3.1 Perbandingan Kualitas Solusi . . . 25
4.3.2 Perbandingan Durasi Pencarian . . . 25
4.3.3 Konsistensi Hasil Eksperimen . . . 26
4.3.4 Pengaruh Parameter Genetic Algorithm . . . 26

5 Kesimpulan dan Saran **27**
5.1 Kesimpulan . . . 27
5.2 Saran . . . 27

6 Pembagian Tugas Tiap Anggota Kelompok **27**

Daftar Pustaka **27**

A Form Penggunaan Generative AI **27**

B Lampiran Lainnya (Bila Ada) **27**

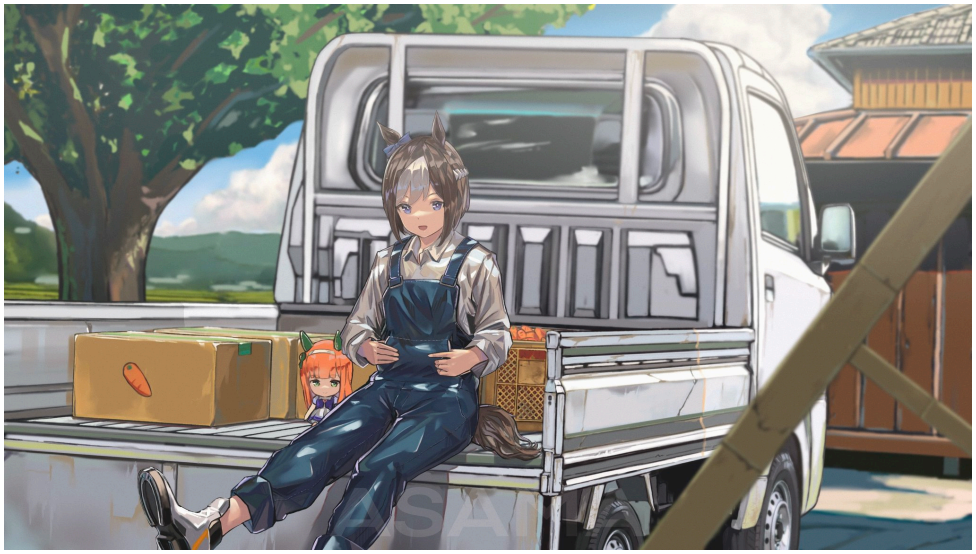
C Bukti Pengujian Manual **28**

1 Pendahuluan

1.1 Latar Belakang

Saat menyiapkan pengiriman Mejiro Express, Special Week menghadapi paket dengan ukuran, nilai, berat, dan tingkat kerapuhan yang berbeda-beda. Persoalannya adalah menentukan paket yang dapat dimuat ke dalam truk peti kemas beserta penempatannya dalam ruang tiga dimensi. Paket bernilai tinggi menarik untuk dibawa, tetapi ruang peti kemas dan kapasitas angkut truk terbatas. Selain itu, susunan harus mencegah paket bertumpang tindih atau melayang, dan paket rapuh tidak boleh menjadi penopang paket lain [1].

Keputusan pemilihan dan penempatan saling berkaitan. Memuat suatu paket mengurangi ruang tersisa dan menambah berat muatan, sedangkan posisi dan orientasinya memengaruhi kemungkinan menempatkan paket lain dengan memenuhi batasan keselamatan. Oleh sebab itu, persoalan ini mencakup pemilihan paket sekaligus penyusunan seluruh paket yang dimuat, sementara paket yang tidak terpilih tetap berada di luar peti kemas.



Gambar 1. Mejiro Express sebagaimana ditunjukkan dalam spesifikasi (Sumber: 真夏の銀堡垒🐴C108土曜日 東地区 ホ-10a on X).

1.2 Rumusan Persoalan dan Tujuan

Persoalan menerima paket berbentuk balok atau kubus serta peti kemas dengan ukuran dan kapasitas angkut tertentu. Setiap paket dapat dipilih untuk dimuat atau dibiarkan di luar, dan paket yang dimuat perlu ditempatkan dengan posisi serta orientasi yang sesuai. Tujuannya adalah memperoleh susunan yang memenuhi batas ruang, kapasitas berat, dan aturan penopang, dengan total nilai paket termuat sebesar mungkin [1].

1.3 Entitas dan Atribut

Masukan persoalan terdiri atas paket dan sebuah truk. Tabel 1 merangkum atribut yang diperlukan; contoh angka hanya ilustrasi, bukan data fixture maupun hasil eksperimen.

Entitas	Atribut	Contoh	Keterangan
Paket	ID	`RusdiPackage`	Identitas paket.
Paket	Dimensions	$\{w:3, l:4, h:1\}$	Lebar w (*width*), panjang l (*length*), dan tinggi h (*height*) paket.
Paket	Orientation	$\{w:x, l:y, h:z\}$	Enam pemetaan sumbu yang sejajar dengan sisi paket. Rotasi 90° terhadap z mengubah contoh menjadi $\{w:y, l:x, h:z\}$.
Paket	Value	60	Nilai paket dalam satuan unit.
Paket	Weight	5	Berat dalam satuan berat.
Paket	IsFragile	`False`	Boolean; `False` berarti tidak rapuh.
Paket	ETA	3	Perkiraan sisa hari hingga kedatangan (*Estimated Time of Arrival*).
Truk	Dimensions	$\{w:10, l:20, h:5\}$	Lebar w, panjang l, dan tinggi h peti kemas.
Truk	MaxCapacity	500	Kapasitas maksimum dalam satuan berat.

Tabel 1. Entitas, atribut, dan contoh ilustratif persoalan.

1.4 Ketentuan Representasi

Paket dan peti kemas berbentuk balok atau kubus dengan dimensi yang dapat berbeda. Secara konseptual, data dapat dinyatakan sebagai pasangan kunci-nilai seperti JSON, tanpa membatasi struktur data. State mencakup semua paket: paket termuat berada seluruhnya di dalam peti kemas, sedangkan yang tidak termuat berada seluruhnya di luar. Posisi dinyatakan dengan koordinat bilangan bulat tiga dimensi. Orientasi memiliki enam permutasi dimensi, yang diperoleh melalui rotasi 90° terhadap sumbu x, y, atau z. State awal dibangkitkan secara acak.

Langkah perubahan (*move*) untuk membentuk tetangga (*neighbor*) pada setiap iterasi meliputi:

1. Menukar penempatan dua paket, baik keduanya di dalam, keduanya di luar, maupun satu di dalam dan satu di luar peti kemas.
2. Memindahkan paket ke koordinat yang berbeda.
3. Merotasi paket 90° terhadap sumbu x, y, atau z.

Representasi solusi akhir (*final state*) memetakan seluruh paket ke status, posisi, dan orientasinya, serta menentukan keterisian setiap koordinat dalam peti kemas. State dan visualisasi harus menunjukkan:

1. Keadaan seluruh paket, baik yang termuat maupun yang berada di luar.
2. Keadaan peti kemas pada truk.
3. Total nilai paket pada state tersebut.

Ketentuan ini tidak menetapkan struktur penyimpanan tertentu untuk pemetaan tersebut [1].

1.5 Batasan Persoalan

Untuk paket termuat i, nyatakan sudut kiri-bawah-belakang sebagai (x_i, y_i, z_i) dan dimensi efektif sebagai (w_i, l_i, h_i). Alas setiap paket termuat adalah

$$B_i = \{(x, y, z_i) \mid x_i \leq x < x_i + w_i,\ y_i \leq y < y_i + l_i\}. \tag{1}$$

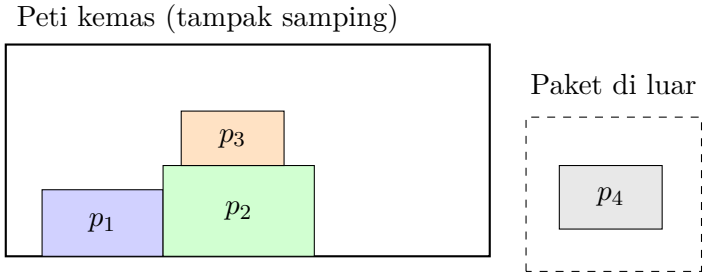
Seluruh volume paket termuat harus berada di dalam batas truk. Paket-paket tidak boleh berbagi volume; dua paket boleh bersentuhan pada batas permukaannya. Titik alas memiliki penopang (*support*) apabila $z_i = 0$, yaitu berada di lantai truk, atau permukaan atas paket lain berada tepat di bawah titik tersebut. Paket disebut melayang apabila tidak ada satu pun titik alas yang memiliki penopang. Dengan demikian, dukungan parsial cukup; seluruh alas tidak harus ditopang. Paket rapuh tidak boleh menjadi penopang paket lain, dan jumlah berat paket termuat tidak boleh melebihi kapasitas truk [1]. Himpunan $\mathcal{F}$ menyatakan seluruh susunan yang memenuhi batasan tersebut.

1.6 Fungsi Objektif

Untuk satu truk, tujuan persoalan adalah memaksimalkan total nilai paket termuat di antara susunan yang sah:

$$\max_{s \in \mathcal{F}} f(s), \qquad f(s) = \sum_{i \text{ termuat pada } s} \text{Value}_i. \tag{2}$$

Paket di luar peti kemas tidak berkontribusi terhadap nilai tersebut. ETA merupakan atribut paket, tetapi tidak menjadi bobot pada fungsi objektif utama [1].



Gambar 2. Ilustrasi konseptual paket termuat dan paket di luar peti kemas. Susunan sebenarnya ditentukan dalam tiga dimensi.

2 Dasar Teori

2.1 Optimasi dan *Local Search*

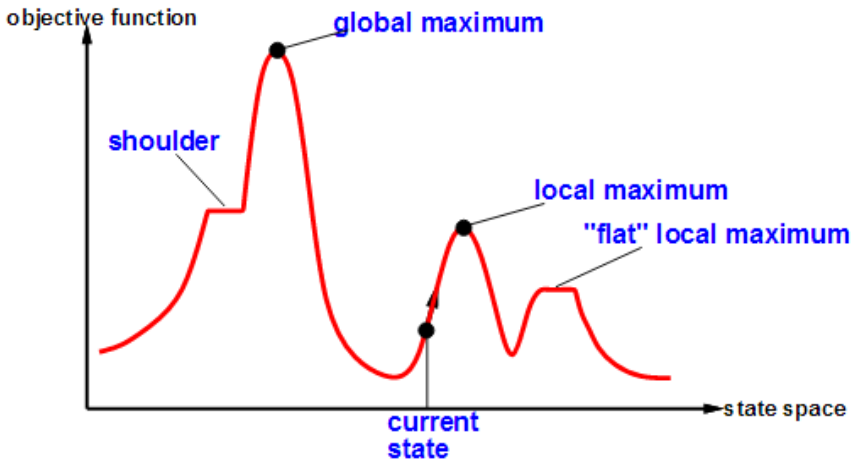
Dalam optimasi, *objective function* memberi nilai pada setiap kandidat solusi, dan pencarian diarahkan pada kandidat bernilai tinggi. Jika terdapat ***constraint*** (batasan), kandidat yang dipertimbangkan termasuk dalam himpunan yang memenuhi batasan tersebut. Dengan $\mathcal{F}$ sebagai himpunan kandidat yang sah, tujuan umum masalah maksimisasi dapat ditulis $\max_{s \in \mathcal{F}} f(s)$, dengan $f(s)$ sebagai nilai kandidat s [2].

Local search bekerja pada satu kandidat lengkap dan memperbaikinya melalui perubahan bertahap. Nilai solusi ditentukan oleh konfigurasi akhir, bukan urutan perubahan yang membentuknya. Pendekatan ini sesuai ketika ruang kemungkinan terlalu besar untuk diperiksa satu per satu [2, 3].

2.2 *State*, *Neighbor*, dan *Search Landscape*

State (keadaan) adalah kandidat solusi yang lengkap. Pencarian berawal dari *initial state* (state awal), yang dapat dibangkitkan secara acak. Sebuah *move* (langkah perubahan) menghasilkan ***neighbor*** (tetangga), yaitu state yang berbeda pada sebagian komponennya. Kumpulan neighbor yang dapat dicapai menentukan arah perpindahan dari state saat ini [3].

Nilai setiap state dapat dibayangkan sebagai ketinggian dalam *search landscape* (lanskap pencarian). ***Local maximum*** (puncak lokal) bernilai setidaknya sama tinggi dengan seluruh neighbor-nya, walaupun state lain mungkin memiliki nilai lebih tinggi. Nilai tertinggi di seluruh ruang pencarian disebut *global maximum* (puncak global). *Plateau* (daerah datar) merupakan kumpulan state bertetangga dengan nilai yang sama. Puncak lokal dan plateau menjelaskan mengapa pencarian yang hanya menerima kenaikan nilai dapat berhenti sebelum mencapai nilai tertinggi keseluruhan [2, 3].



Gambar 3. *Search landscape* dengan global maximum, local maximum, dan plateau. Diambil dari salindia *Beyond Classical Search* [3].

2.3 *Hill Climbing*

Seperti terlihat pada Gambar 3, pencarian yang hanya memilih kenaikan nilai dapat berhenti di local maximum. ***Hill climbing*** memulai dari satu state, membandingkannya dengan neighbor, lalu berpindah menurut aturan varian yang digunakan. Pada *steepest-ascent hill climbing*, versi teoretis mengevaluasi seluruh neighbor dan memilih yang memiliki nilai tertinggi, selama nilainya melebihi state saat ini. Jika beberapa neighbor sama-sama terbaik, pemilihan salah satunya tidak mengubah nilai yang dicapai pada langkah itu.

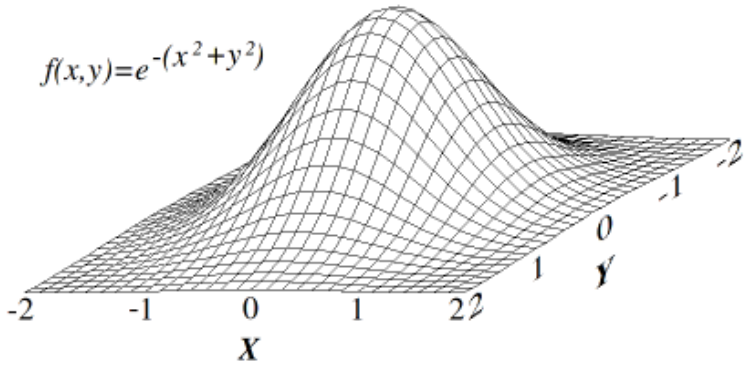
Dalam implementasi, seluruh neighborhood tidak diperiksa. Algoritma membangkitkan sampel terbatas neighbor yang sah, lalu memilih kandidat bernilai tertinggi dari sampel tersebut. Karena itu, **pemeriksaan terbatas pada sampel** berarti tidak ditemukannya peningkatan hanya menunjukkan bahwa sampel saat itu tidak memuat kandidat yang lebih baik; keadaan ini belum memastikan semua neighbor sudah diperiksa. Steepest-ascent menghindari langkah yang menurunkan atau mempertahankan skor, sehingga pencarian dapat berakhir di puncak lokal atau berhenti saat sampelnya tidak menunjukkan kenaikan [2, 3].

Stochastic hill climbing memilih secara acak dari neighbor yang meningkatkan skor. Pemilihan seragam memberi setiap kandidat peningkat peluang yang sama, sedangkan skema berbobot dapat memberi peluang lebih besar kepada kenaikan yang lebih besar. Implementasi menggunakan **pemilihan seragam**, bukan pembobotan berdasarkan besar kenaikan. Cara ini dapat mengambil langkah yang tidak terbaik pada sampel, tetapi tetap menuntut peningkatan ketat; akibatnya, pencarian berhenti ketika sampel tidak menyediakan peningkat dan tidak bergerak melintasi plateau [2, 3].

Hill climbing with sideways move juga menerima neighbor yang skornya sama, sehingga dapat bergerak di antara state pada plateau dan mungkin mencapai state yang memiliki peningkatan di sisi lain. Langkah setara tidak menaikkan skor, dan tanpa batas dapat membuat pencarian berputar atau bergerak lama tanpa kemajuan. Karena itu, **jumlah langkah setara berturut-turut dibatasi**. Langkah yang meningkatkan skor mengatur ulang hitungan tersebut; setelah batas tercapai, langkah setara berikutnya ditolak, sementara peningkatan ketat tetap dapat diterima.

Random-restart hill climbing mengulang steepest-ascent dari state awal berbeda untuk mencoba wilayah pencarian lain. Implementasi menjalankan satu climb dari state awal yang diberikan, lalu melakukan 10 restart, sehingga terdapat 11 climb. Setiap climb memiliki anggaran iterasinya sendiri; total pekerjaan dapat lebih besar daripada satu climb, tetapi jumlah restart dan sampel tetap membatasi bagian ruang yang diperiksa. Hasil terbaik dipilih dari seluruh climb, sedangkan state akhir adalah hasil climb terakhir. Restart dapat mengurangi ketergantungan pada satu puncak lokal, tetapi tidak memastikan optimum global; pencarian tetap tidak mengetahui solusi terbaik yang belum dikunjungi [2, 3].

Gambar 4 memperlihatkan fungsi dua variabel dengan satu puncak. Pada masalah maksimisasi, perpindahan ke nilai yang lebih tinggi dapat dibayangkan sebagai langkah menaiki permukaan tersebut. Susunan paket merupakan state diskret dengan banyak constraint, sehingga lanskapnya tidak harus sehalus ilustrasi ini; puncak lokal dan plateau tetap menjadi hambatan seperti pada Gambar 3.



Gambar 4. Ilustrasi permukaan objektif untuk hill climbing. Sumber: Wikimedia Commons, *Hill climb.png*.

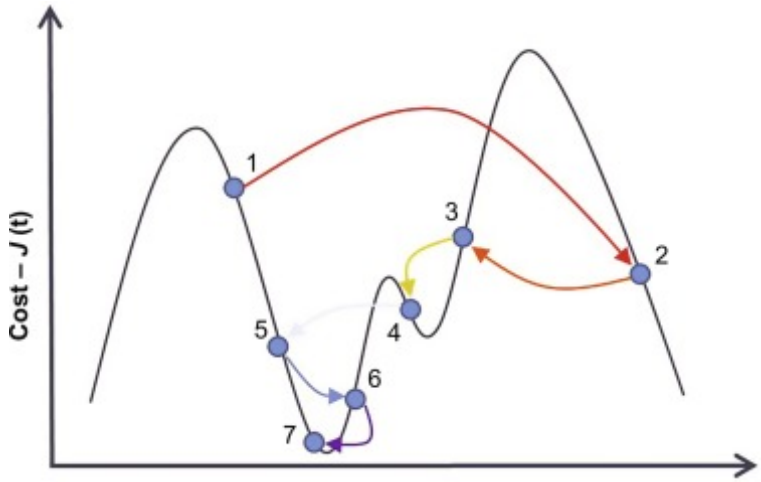
2.4 *Simulated Annealing*

Hill climbing tidak selalu bisa keluar dari local maximum dengan move yang hanya memperbaiki nilai. ***Simulated annealing*** sesekali menerima move yang menurunkan nilai agar pencarian dapat berpindah ke daerah lain. Peluang menerima penurunan ditentukan oleh *temperature* (temperatur). Untuk $\Delta f = f(s') - f(s) < 0$ dan $T > 0$, peluang menerima neighbor s' adalah

$$\Pr(\text{accept } s') = \exp\left(\frac{\Delta f}{T}\right). \tag{3}$$

Pada temperature tinggi, algoritma lebih sering menerima penurunan nilai sehingga dapat keluar dari local maximum. Seiring temperature turun, peluang itu mengecil. *Cooling schedule* (jadwal penurunan temperatur) menentukan seberapa cepat perilaku pencarian berubah. Jadwal yang terlalu cepat dapat membuat pencarian kembali terjebak sebelum sempat menjelajahi state lain [2, 3].

Gambar 5 menunjukkan perpindahan pada lanskap biaya, termasuk langkah yang sementara menaikkan biaya sebelum pencarian mencapai daerah yang lebih rendah. Ilustrasi ini memakai sudut pandang minimisasi. Untuk persoalan pemuatan yang memaksimalkan $f(s)$, biaya dapat dinyatakan sebagai $E(s) = -f(s)$, sehingga kenaikan biaya pada gambar setara dengan penurunan skor objektif yang sesekali diterima oleh SA.

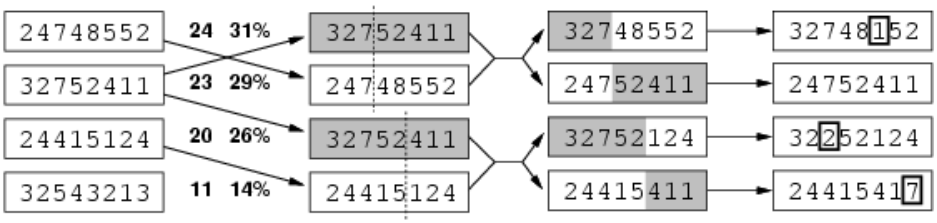


Gambar 5. Ilustrasi perpindahan simulated annealing pada lanskap biaya. Sumber: Elsevier, ilustrasi 2.14.

2.5 *Genetic Algorithm*

Jika hill climbing dan simulated annealing mengubah satu state dalam satu lintasan pencarian, ***genetic algorithm*** bekerja dengan *population* (populasi) yang berisi sejumlah *individual* (kandidat solusi). Setiap individual dinilai memakai *fitness function* (fungsi penilaian). Melalui *selection* (pemilihan induk), individual yang lebih baik mendapat peluang lebih besar untuk menghasilkan keturunan [2, 3].

Generasi baru dibentuk melalui *crossover* (penggabungan bagian dari dua induk) dan *mutation* (perubahan acak pada individual). Crossover mewariskan bagian dari solusi yang sudah ada, sementara mutation membantu menjaga keragaman population. Ukuran population dan banyaknya *generation* (generasi) memengaruhi jumlah kandidat yang diperiksa serta waktu pencarian. Bila suatu operator menghasilkan kandidat yang melanggar constraint, kandidat itu perlu ditangani sebelum dipakai sebagai solusi [2, 3].



Gambar 6. Alur selection, crossover, dan mutation pada genetic algorithm. Diambil dari salindia *Beyond Classical Search* [3].

3 Pembahasan dan Implementasi

3.1 Arsitektur Aplikasi

Pengguna mengubah paket dan truk melalui formulir web yang dimulai dari fixture armada bawaan di `src/frontend/src/mocks/fleetFixture.ts`. Belum ada alur impor berkas problem.

Konfigurasi diperiksa melalui endpoint `POST /api/problems/validate`. Endpoint ini memvalidasi model dan batas masukan, bukan susunan paket. Ketika run dimulai, frontend memeriksa parameter lalu mengirim problem, algoritma, seed, objektif, parameter, dan pilihan riwayat ke `POST /api/experiments/run`. Backend memvalidasi skema dan anggaran eksekusi, membangkitkan state awal, menjalankan algoritma, lalu memeriksa kelayakan state awal, akhir, dan terbaik serta kecocokan skornya sebelum membentuk respons.

Run dari UI secara default menyimpan hasil; opsi simpan dapat diubah melalui kontrol pada panel setup. Daftar run tersimpan dimuat dan dapat diperbarui melalui UI, serta tersedia melalui `GET/api/experiments`. Endpoint preset GA dan batch tersedia melalui `GET/api/experiments/presets/genetic_algorithm` dan `POST/api/experiments/batch`. Problem yang sedang diedit untuk run berikutnya terpisah dari problem asli milik run yang sedang ditampilkan.

3.1.1 Struktur Aplikasi

Folder utama aplikasi tersusun sebagai berikut. Pohon ini hanya menampilkan direktori yang berperan dalam alur pencarian dan visualisasi.

```
.
|-- data/
|-- output/
|-- src/
    |-- backend/
    | |-- app/
    | |-- api/
    | |-- domain/
    | |-- experiments/
    | |-- optimization/
    |-- frontend/
        |-- src/
            |-- api/
            |-- charts/
            |-- modals/
            |-- panels/
            |-- scene/
            |-- shell/
            |-- stores/
            |-- mocks/
```

Di backend, `domain` mendefinisikan data, `optimization` memuat validator dan algoritma, sedangkan `experiments` mengatur eksekusi, ringkasan, dan pencatatan hasil. Di frontend, `api` menangani request serta pemeriksaan respons; `charts`, `modals`, `panels`, `scene`, dan `shell` memisahkan grafik, dialog, panel, visualisasi tiga dimensi, dan kontrol antarmuka. Fixture armada berada di `src/frontend/src/mocks`; `stores` memuat state eksperimen aktif serta replay, sedangkan daftar run tersimpan dikelola di aplikasi.

Direktori `data/` belum memuat dataset. Direktori keluaran ditentukan oleh konfigurasi `output_dir` (default `output/`); run tersimpan berada di subdirektori `experiments/`, sementara batch menyimpan run individual di sana serta ringkasan JSON dan CSV di `batches/`. Repositori belum memuat hasil studi terukur yang terkonsolidasi; keberadaan keluaran lokal tidak menjadi bukti bahwa rancangan studi dalam laporan ini telah dilaksanakan.

3.1.2 Tech Stack

Backend ditulis dengan **Python 3.12**. **FastAPI** menyediakan endpoint untuk memvalidasi problem, menjalankan eksperimen tunggal atau batch, dan membaca hasil yang tersimpan. Model **Pydantic** memeriksa tipe serta rentang nilai saat request diterima. Sesudah itu, modul optimasi menjalankan aturan yang sama untuk semua algoritma. **NumPy** digunakan untuk occupancy grid tiga dimensi, sehingga pemeriksaan ruang terisi dapat dilakukan pada irisan sel paket.

Frontend dibangun dengan **React** dan **TypeScript**. Komponen React memisahkan form problem, kontrol pencarian, visualisasi, dan ringkasan hasil. TypeScript membantu menjaga bentuk request dan respons tetap sesuai kontrak backend. **Vite** dipakai untuk menjalankan frontend selama pengembangan dan menghasilkan berkas aplikasi saat build.

Untuk menampilkan hasil, **React Three Fiber** dan **Three.js** menggambar peti kemas serta posisi paket dalam ruang tiga dimensi. **Recharts** menampilkan perubahan skor selama iterasi. **Zustand** menyimpan state eksperimen aktif serta indeks iterasi untuk replay.

3.2 Pemodelan Problem dan Constraint

Pemodelan dimulai dari data paket dan truk. Dari data itu, program membentuk state yang mencatat posisi setiap paket. State lalu melewati pemeriksaan constraint sebelum objective dihitung. Urutan ini dipakai bersama oleh seluruh algoritma, sehingga nilai yang dibandingkan selalu berasal dari **susunan yang sah**.

3.2.1 Data Problem

Sesuai atribut konseptual pada Subbab 1.3, `Problem` menyimpan daftar `PackageSpec` dan `TruckSpec`. Dimensi lebar, panjang, dan tinggi diratakan menjadi field `width`, `length`, dan `height`; `IsFragile` menjadi `is_fragile`, dan `MaxCapacity` menjadi `max_capacity`. Atribut `Value`, `Weight`, dan `ETA` masing-masing disimpan sebagai `value`, `weight`, dan `eta`. Truk memiliki `id` sebagai identitas implementasi tambahan. Dukungan beberapa truk merupakan perluasan dari persoalan satu truk; setiap paket ditugaskan ke paling banyak satu truk. Cuplikan 1 hingga 3 memperlihatkan hubungan ketiga kelas tersebut.

Validasi masukan dilakukan sejak model dibuat. Dimensi harus berupa bilangan bulat positif, sedangkan nilai, berat, ETA, dan kapasitas tidak boleh negatif maupun tak hingga. `Problem` menolak ID paket atau truk yang berulang dan mensyaratkan setidaknya satu truk. Karena `trucks` berupa daftar, struktur yang sama dapat dipakai untuk satu truk maupun beberapa truk. Setelah data ini tersedia, penempatan setiap paket dicatat dalam state.

Cuplikan 1. Atribut paket pada `PackageSpec`

```
class PackageSpec(BaseModel):
    model_config = ConfigDict(frozen=True, allow_inf_nan=False)

    id: str
    width: int = Field(gt=0)
    length: int = Field(gt=0)
    height: int = Field(gt=0)
    value: float = Field(ge=0)
    weight: float = Field(ge=0)
    is_fragile: bool
    eta: int = Field(ge=0)
```

Cuplikan 2. Atribut truk pada `TruckSpec`

```
class TruckSpec(BaseModel):
    model_config = ConfigDict(frozen=True, allow_inf_nan=False)

    id: str
    width: int = Field(gt=0)
    length: int = Field(gt=0)
    height: int = Field(gt=0)
    max_capacity: float = Field(ge=0)
```

Cuplikan 3. Daftar paket dan truk dalam `Problem`

```
class Problem(BaseModel):
    packages: list[PackageSpec]
    trucks: list[TruckSpec]

    @model_validator(mode="after")
    def validate_ids_and_trucks(self) -> "Problem":
        if not self.trucks:
            raise ValueError("at least one truck is required")
        if len({package.id for package in self.packages}) != len(self.packages):
            raise ValueError("package IDs must be unique")
        if len({truck.id for truck in self.trucks}) != len(self.trucks):
            raise ValueError("truck IDs must be unique")
        return self
```

3.2.2 Representasi State dan Orientasi

Kelas `State` berisi daftar `PackagePlacement`, sesuai Subbab 1.4. Pada state yang sah, setiap paket memiliki tepat satu placement berisi ID paket dan truk, `Position`, serta `Orientation`. Orientasi disimpan pada placement, bukan `PackageSpec`. Posisi menunjuk sudut kiri-bawah-belakang (x mengikuti lebar, y panjang, z tinggi). Paket di luar memiliki `truck_id` dan `position` bernilai `None`. Posisi dan orientasi pada placement, bersama dimensi pada `PackageSpec`, menentukan pemetaan spasial; grid keterisian dibentuk saat validasi, bukan diserialisasi sebagai bagian terpisah dari `State`.

Cuplikan 4. Model penempatan paket

```
class PackagePlacement(BaseModel):
    package_id: str
    truck_id: str | None = None
    position: Position | None = None
    orientation: Orientation = Orientation.WLH

    @model_validator(mode="after")
    def validate_assignment(self) -> "PackagePlacement":
        if (self.truck_id is None) != (self.position is None):
            raise ValueError("truck_id and position must both be set or both be None")
        return self
```

Enam pilihan `Orientation` didefinisikan pada `app/domain/package.py`. Fungsi `get_oriented_dimensions` mengubah orientasi menjadi dimensi efektif (w_i, l_i, h_i) tanpa mengubah dimensi asli paket. Untuk kubus atau balok dengan sisi yang sama, beberapa orientasi menghasilkan dimensi efektif identik. Fungsi `get_unique_orientations` menghapus pilihan duplikat tersebut saat orientasi akan diacak. State yang terbentuk kemudian diperiksa sebagai satu kesatuan, bukan per paket saja.

3.2.3 Validasi Constraint

Fungsi `validate_state` pada `app/optimization/constraints.py` menjadi **pemeriksa akhir setiap kandidat** terhadap batasan Subbab 1.5, termasuk alas B_i pada Persamaan 1 dan dukungan parsial. Pemeriksaan dimulai dari kelengkapan assignment. Setiap paket dalam `Problem` harus muncul sekali dalam `State`, sedangkan ID paket dan truk yang tidak dikenal ditolak. Paket yang berada di luar tidak memakai ruang maupun kapasitas truk.

Validator membuat *occupancy grid* (grid keterisian) NumPy bagi setiap truk. Bentuk grid mengikuti (W_t, L_t, H_t), dengan sel kosong bernilai -1 dan sel terisi menyimpan indeks paket. Jika paket i ditempatkan di truk t pada (x_i, y_i, z_i) dengan dimensi efektif (w_i, l_i, h_i), seluruh bagian paket harus memenuhi

$$\begin{aligned} 0 \le x_i, \quad x_i + w_i \le W_t, \\ 0 \le y_i, \quad y_i + l_i \le L_t, \\ 0 \le z_i, \quad z_i + h_i \le H_t. \end{aligned} \tag{4}$$

Dalam kode, `_collect_occupancies` membandingkan posisi dan dimensi paket dengan ukuran grid. Cuplikan 5 menunjukkan pemeriksaan paket yang melewati dinding peti kemas. Setelah lolos, irisan sel yang akan ditempati diperiksa lagi. Cuplikan 6 menolak

paket ketika irisan tersebut sudah berisi indeks paket lain. Karena grid dibuat per truk, paket pada truk berbeda tidak saling bertabrakan.

Cuplikan 5. Pemeriksaan batas peti kemas

```
if any(
    start < 0 or start + size > limit
    for start, size, limit in zip(origin, dimensions, grid.shape, strict=True)
):
    errors.append(
        f"Package {placement.package_id} is out of bounds in truck {truck_id}"
    )
    unsafe_trucks.add(truck_id)
    continue
```

Cuplikan 6. Pemeriksaan overlap pada occupancy grid

```
for placement, package_index, region in regions:
    truck_id = placement.truck_id
    assert truck_id is not None
    cells = occupancies[truck_id][region]
    if np.any(cells != -1):
        errors.append(
            f"Package {placement.package_id} overlaps another in truck {truck_id}"
        )
        unsafe_trucks.add(truck_id)
        continue
    cells[...] = package_index
```

Paket pada $z_i = 0$ ditopang oleh lantai truk. Untuk paket di atas lantai, validator memeriksa sel tepat di bawah alasnya, yakni pada $z_i - 1$. Paket dinyatakan **melayang** jika tidak ada satu pun sel alas yang mendapat support dari paket lain. Jika ada support tetapi salah satu paket penopang bersifat rapuh, susunan juga ditolak. Pemeriksaan ini mengikuti definisi support pada tugas, yaitu cukup ada satu titik alas yang ditopang. Validator tidak mensyaratkan seluruh alas paket bersentuhan dengan penopang. Bagian inti pemeriksaan tersebut tampak pada Cuplikan 7.

Cuplikan 7. Pemeriksaan support dan paket rapuh

```
w, l, _ = get_oriented_dimensions(
    packages[placement.package_id], placement.orientation
)
x, y, z = position.x, position.y, position.z
below = occupancies[truck_id][x : x + w, y : y + l, z - 1]
supporters = np.unique(below[below >= 0])
if supporters.size == 0:
    support_errors.append(
        f"Package {placement.package_id} is floating in truck {truck_id}"
    )
elif any(problem.packages[int(index)].is_fragile for index in supporters):
    fragile_errors.append(
        f"Package {placement.package_id} rests on fragile support "
        f"in truck {truck_id}"
    )
```

Setelah posisi dan support diperiksa, validator menghitung beban setiap truk. Untuk truk t, jumlah berat paket yang ditugaskan kepadanya harus memenuhi

$$\sum_{i \in P_t} \text{weight}_i \leq \text{max_capacity}_t. \tag{5}$$

Cuplikan 8 menunjukkan bahwa berat dijumlahkan dengan `Decimal`. Dengan cara ini, batas seperti $0.1 + 0.2 \leq 0.3$ tidak keliru akibat pembulatan bilangan *floating point*. Hasil `validate_state` berupa `ValidationResult` yang memuat status `valid`, daftar `errors`, dan total berat per truk. Jika assignment atau geometri sudah ambigu, pemeriksaan support dilewati karena grid tidak lagi dapat dipercaya, sementara kesalahan yang sudah ditemukan tetap dilaporkan.

Cuplikan 8. Penjumlahan berat dan pemeriksaan kapasitas

```
exact_weights = {truck.id: Decimal(0) for truck in problem.trucks}
for placement in loaded:
    assert placement.truck_id is not None
    exact_weights[placement.truck_id] += Decimal(
        str(packages[placement.package_id].weight)
    )
truck_weights = {
    truck_id: float(weight) for truck_id, weight in exact_weights.items()
}
for truck in problem.trucks:
    if exact_weights[truck.id] > Decimal(str(truck.max_capacity)):
        errors.append(
            f"Truck {truck.id} exceeds capacity: "
            f"{truck_weights[truck.id]} > {truck.max_capacity}"
        )
```

3.2.4 Objective Function

Setelah state dinyatakan sah, program menghitung nilainya melalui `ObjectiveMode` pada `app/optimization/objective.py`. **Mode utama**, `TOTAL_VALUE`, mengimplementasikan fungsi objektif pada Persamaan 2 di Subbab 1.6; agregasi seluruh armada merupakan perluasan atas rumusan konseptual satu truk:

$$f_{\text{total}}(s) = \sum_{i:\, \text{truck}_i \neq \text{None}} \text{value}_i. \tag{6}$$

Mode tambahan, `ETA_WEIGHTED_VALUE`, memberi bobot lebih besar pada paket yang ETA-nya lebih dekat. Ini ekstensi opsional, bukan objektif konseptual utama:

$$f_{\text{ETA}}(s) = \sum_{i:\, \text{truck}_i \neq \text{None}} \frac{\text{value}_i}{\text{eta}_i + 1}. \tag{7}$$

Kontribusi setiap paket termuat dihitung oleh `objective_contributions`, lalu dijumlahkan oleh `evaluate_objective` dengan `math.fsum`. Evaluator tidak memberi penalti atas pelanggaran constraint dan tidak memeriksa kelayakan state. Dalam alur pencarian, `validate_state` memeriksa kelayakan sebelum skor digunakan, sehingga **skor hanya dibandingkan di antara state yang sah**.

3.3 Implementasi Algoritma *Local Search*

3.3.1 Inisialisasi State dan Pembangkitan Neighbor

Sebelum pencarian dimulai, `runner.py` membuat satu *random number generator* dari *seed* yang diterima. Generator yang sama diteruskan ke inisialisasi dan algoritma agar run dengan input serta seed yang sama dapat diulang. Hill climbing dan simulated annealing menerima satu initial state dari `generate_random_feasible_state`. Genetic algorithm memakai fungsi yang sama untuk membentuk anggota populasi awal.

Untuk memenuhi ketentuan state awal acak pada Subbab 1.4, inisialisasi memulai semua paket di luar truk, lalu mengacak urutan paket dan tujuan penempatannya. Untuk setiap truk yang dicoba, fungsi memilih orientasi dan posisi. Koordinat x dan y diambil dari rentang yang masih muat, sedangkan z diambil dari lantai atau permukaan atas paket lain. Kandidat baru hanya disimpan bila lolos `validate_state`. Paket dapat tetap di luar saat target luar terpilih atau ketika percobaan penempatan gagal. Cuplikan 9 menunjukkan titik awal konstruksi tersebut.

Cuplikan 9. Pembentukan initial state dalam `initializer.py`

```
state = State(
    placements=[PackagePlacement(package_id=p.id) for p in problem.packages]
)
indices = list(range(len(problem.packages)))
rng.shuffle(indices)
```

Setelah initial state tersedia, neighbor dibentuk melalui tiga operasi pada Subbab 1.4. `RELOCATE` memindahkan paket ke koordinat lain, mengeluarkannya dari truk, atau memuatnya kembali; implementasi multi-truk juga memungkinkan transfer antartruk. `ROTATE` mengubah orientasi paket termuat sambil mempertahankan titik posisinya. `SWAP` menukar tujuan truk dan posisi dua paket, termasuk kasus satu paket di luar, sementara masing-masing mempertahankan orientasinya. Peluang pemilihan awalnya berturut-turut 0,50, 0,25, dan 0,25. Setiap move bekerja pada salinan state agar state asal tidak berubah.

Proposal move belum tentu memenuhi constraint. Untuk hill climbing dan simulated annealing, `generate_random_neighbor` mengulang proposal sampai menemukan state sah atau mencapai batas percobaan, seperti pada Cuplikan 10. Hill climbing dapat meminta beberapa neighbor berbeda melalui `sample_valid_neighbors`, sedangkan simulated annealing mengambil satu. Pada genetic algorithm, proposal mutasi yang belum sah boleh masuk ke tahap repair sebelum dinilai.

Cuplikan 10. Penerimaan neighbor yang sah dalam `neighbors.py`

```
for _ in range(config.max_attempts):
    candidate = propose_random_move(problem, state, rng, config)
    if candidate is not None and validate_state(problem, candidate.state).valid:
        return candidate
return None
```

3.3.2 Hill Climbing

Keempat varian hill climbing diimplementasikan dalam kelas `HillClimbing` pada `app/optimization/algorithms/hill_climbing.py`. Setiap iterasi mengambil sampel neigh-

bor sah melalui `sample_valid_neighbors`, kemudian menghitung objective-nya. Jumlah sampel diatur oleh `candidates_per_iteration`, dengan nilai default 50. Pembangkitan dibatasi hingga jumlah kandidat dikali `max_attempts` percobaan, dengan default 30, sehingga sampel yang diperoleh dapat lebih sedikit dari permintaan. Perbedaan tiap varian terletak pada cara memilih kandidat dan melanjutkan pencarian. Cuplikan berikut merangkum bagian implementasi yang digunakan masing-masing varian, dengan pencatatan riwayat tidak ditampilkan.

Steepest-ascent hill climbing membandingkan skor state saat ini dengan seluruh neighbor sah yang berhasil masuk ke sampel iterasi. Secara teoretis, steepest-ascent memilih neighbor terbaik dari seluruh neighborhood; implementasi hanya dapat memilih yang terbaik dari sampel, yang jumlahnya dibatasi dan dapat kurang dari target bila proposal sah tidak cukup ditemukan. Jadi, `local_optimum` menandai tidak adanya peningkatan pada sampel, bukan bukti bahwa semua neighbor sudah diperiksa. Langkah yang lebih baik dipilih, dan jika beberapa kandidat berbagi skor tertinggi, satu dipilih secara acak seperti pada Cuplikan 11. Aturan ini mengarahkan pencarian ke kenaikan tertinggi yang teramati, tetapi dapat berhenti di puncak lokal atau sebelum menemukan peningkat di luar sampel.

Cuplikan 11. Inti pemilihan neighbor pada steepest-ascent

```
top_score = max(scores)
if top_score <= current_score:
    termination_reason = "local_optimum"
    break
pool = [
    (n, score)
    for n, score in zip(neighbors, scores)
    if score == top_score
]
selected, selected_score = rng.choice(pool)
current, current_score = selected.state, selected_score
```

Stochastic hill climbing menyaring neighbor sah dalam sampel. Kandidat dengan skor yang meningkat ketat kemudian dipilih secara seragam. Peluang tersebut tidak dibobot menurut besar kenaikan: kandidat dengan peningkatan kecil memiliki peluang yang sama dengan kandidat yang lebih tinggi. Akibatnya, langkah terpilih bisa lebih rendah skornya daripada kandidat terbaik dalam sampel, tetapi tetap memperbaiki state saat ini. Cuplikan 12 memperlihatkan penyaringan dan pemilihan itu. Jika tidak ada kandidat peningkat, algoritma berhenti dengan alasan `local_optimum`; riwayat juga mencatat banyaknya kandidat peningkat yang ditemukan. Pilihan acak mengubah lintasan pencarian, tetapi aturan peningkatan ketat membuat varian ini tidak dapat melintasi plateau.

Hill climbing with sideways move memilih kandidat dengan skor tertinggi dalam sampel seperti steepest-ascent, termasuk kandidat yang skornya sama dengan state saat ini. Langkah setara memungkinkan pencarian berpindah di plateau, tempat kenaikan mungkin belum terlihat dari posisi sekarang. Batas `max_sideways` berlaku untuk langkah setara berturut-turut: setiap langkah tersebut menambah penghitung, dan peningkatan skor mengatur ulang penghitung ke nol. Dengan batas default 100, pencarian dapat mengambil hingga 100 langkah setara berurutan; jika langkah setara berikutnya masih diperlukan, pencarian berhenti dengan alasan `max_sideways`. Cuplikan 13 memperlihatkan aturan tersebut. Kandidat yang menurunkan skor tetap ditolak, dan jumlah

Cuplikan 12. Pemilihan acak dari neighbor peningkat pada stochastic

```
if is_stochastic:
    pool = [
        (n, score)
        for n, score in zip(neighbors, scores)
        if score > current_score
    ]
    if not pool:
        termination_reason = "local_optimum"
        break
    selected, selected_score = rng.choice(pool)
    current, current_score = selected.state, selected_score
```

langkah sideways dicatat. Batas ini mengendalikan penelusuran plateau, tetapi tidak menjamin bahwa plateau telah ditelusuri seluruhnya.

Cuplikan 13. Penerimaan dan penghitungan sideways move

```
if top_score > current_score or (
    top_score == current_score and consecutive_sideways < max_sideways
):
    pool = [
        (n, score)
        for n, score in zip(neighbors, scores)
        if score == top_score
    ]
    selected, selected_score = rng.choice(pool)
    improved = selected_score > current_score
    current, current_score = selected.state, selected_score
    if improved:
        consecutive_sideways = 0
    else:
        consecutive_sideways += 1
        sideways_moves += 1
```

Random-restart hill climbing memakai steepest-ascent untuk setiap climb, dimulai dari state awal runner lalu dilanjutkan dengan state sah baru pada tiap restart. Dengan 10 restart, implementasi melakukan 11 climb. Setiap climb mendapat batas `max_iterations` sendiri, sehingga anggaran itu berlaku per climb, bukan dibagi di antara semua restart. Cuplikan 14 memperlihatkan pengulangan dan pemilihan hasil: **state akhir** berasal dari climb terakhir, sedangkan `best_state` dan skor terbaik berasal dari climb dengan hasil tertinggi di seluruh pengulangan. Riwayat menggabungkan iterasi dengan penanda restart dan skor terbaik kumulatif. Restart memberi kesempatan untuk memulai dari wilayah lain dan mengurangi risiko bergantung pada satu puncak lokal, dengan biaya climb tambahan. Karena jumlahnya tetap terbatas dan tiap climb hanya memeriksa sampel neighborhood, metode ini tidak memastikan pencarian menemukan optimum global.

Setiap climb juga berhenti jika tidak ada neighbor sah (`no_valid_neighbor`) atau batas iterasi tercapai (`max_iterations`). State saat ini dan state terbaik disimpan terpisah. Melalui API, pencarian dibatasi hingga 2.000 iterasi per climb, 50 kandidat per iterasi, dan 20 restart.

Cuplikan 14. Pengulangan steepest-ascent pada random restart

```
start = initial_state
for restart in range(config.max_restarts + 1):
    if restart > 0:
        start = generate_random_feasible_state(problem, rng)
    climb = self._climb(
        problem,
        start,
        variant=HillClimbingVariant.STEEPEST_ASCENT,
        objective_mode=objective_mode,
        rng=rng,
        config=config,
        include_state_history=include_state_history,
    )
    climbs.append(climb)
best = max(climbs, key=lambda climb: climb.best_score)
```

3.3.3 Simulated Annealing

Kelas `SimulatedAnnealing` memulai pencarian dari state sah yang sama jenisnya dengan hill climbing, tetapi hanya mengambil **satu neighbor acak** pada setiap iterasi. Move dengan $\Delta f \geq 0$ langsung diterima. Untuk $\Delta f < 0$, algoritma menggunakan peluang $\exp(\Delta f/T)$ sebagaimana dijelaskan pada Bab 2. Cuplikan 15 menunjukkan keputusan tersebut di dalam kode.

Cuplikan 15. Penerimaan move pada `simulated_annealing.py`

```
delta = candidate_score - current_score
acceptance_probability = (
    1.0 if delta >= 0 else math.exp(delta / temperature)
)
accepted = delta >= 0 or rng.random() < acceptance_probability
if accepted:
    current = candidate.state.model_copy(deep=True)
    current_score = candidate_score
```

Temperatur awal dapat diberikan sebagai parameter. Jika kosong, nilainya diambil dari rata-rata value paket dengan batas bawah 1. Setelah satu iterasi selesai, temperatur dikalikan `alpha`, yang bernilai antara nol dan satu. Pencarian berhenti saat temperatur berada di bawah `min_temperature`, batas iterasi tercapai, atau neighbor sah tidak ditemukan. `best_state` disimpan terpisah dari state saat ini, sebab simulated annealing dapat menerima move yang menurunkan skor. Riwayat iterasi mencatat temperatur, peluang penerimaan, keputusan move, dan skor. Parameter `stuck_patience` hanya menandai dan menghitung kejadian ketika skor terbaik tidak membaik cukup lama; parameter ini tidak menghentikan pencarian.

3.3.4 Genetic Algorithm

Kelas `GeneticAlgorithm` memulai pencarian dengan **populasi state sah**. Runner tidak memberikan initial state tunggal; algoritma membangkitkan populasi awal, lalu champion populasi tersebut dicatat sebagai `initial_state` dan `initial_score` pada hasil. Satu state menjadi satu individual dan objective-nya menjadi fitness. Pemilihan induk memakai `roulette_select`, sehingga fitness lebih tinggi mendapat peluang lebih besar.

Jika semua fitness nol, induk dipilih seragam secara acak. `uniform_crossover` menyusun anak dengan mengambil placement setiap paket dari salah satu dari dua induk, masing-masing dengan peluang setengah.

Dalam setiap generasi, satu individual dengan fitness tertinggi disalin langsung sebagai *elite*. Individual lain dibentuk melalui selection, crossover sesuai `crossover_probability`, dan mutation sesuai `mutation_probability`. Mutation memilih salah satu dari relocate, rotate, atau swap. Sebelum masuk ke populasi berikutnya, anak diproses oleh `repair_state`, seperti terlihat pada Cuplikan 16.

Cuplikan 16. Pembentukan generasi baru pada `genetic_algorithm.py`

```
next_population = [champion.model_copy(deep=True)]
while len(next_population) < config.population_size:
    parent_a = roulette_select(population, fitnesses, rng)
    parent_b = roulette_select(population, fitnesses, rng)
    if rng.random() < config.crossover_probability:
        child = uniform_crossover(problem, parent_a, parent_b, rng)
    else:
        child = rng.choice((parent_a, parent_b)).model_copy(deep=True)
    if rng.random() < config.mutation_probability:
        proposal = rng.choice(
            (propose_relocate, propose_rotate, propose_swap)
        )(problem, child, rng)
        if proposal is not None:
            child = proposal.state
    next_population.append(repair_state(problem, child, rng))
```

Repair memulai dari state dengan semua paket di luar, lalu memproses paket termuat menurut koordinat z dan ID. Untuk tiap paket, placement genetik yang sama dicoba terlebih dahulu. Jika tidak sah, repair memindai kembali truk yang diminta lalu truk lain, mencoba orientasi genetik dan alternatifnya, serta memeriksa koordinat berurutan menurut z, y, lalu x. Paket tetap di luar jika tidak ditemukan placement sah. Setiap generasi mencatat maksimum dan rata-rata fitness populasi; riwayat dimulai pada generasi 0, sehingga memiliki $G + 1$ catatan untuk G generasi. Champion generasi terakhir menjadi state akhir, sementara state terbaik sepanjang run disimpan terpisah. Elitisme mempertahankan satu champion. Default parameter GA adalah populasi 50, 100 generasi, peluang crossover 0,80, peluang mutasi 0,20, dan satu elite; nilai dan rentang yang ditampilkan pada form frontend bersumber dari endpoint batas backend. Batas API ialah populasi 100 dan 200 generasi.

4 Eksperimen dan Analisis

4.1 Rancangan Eksperimen

Bagian ini menyajikan rancangan dan hasil pengujian manual melalui UI. Hasil pengujian mencakup 15 run: 12 run Hill Climbing (HC) dan tiga run Simulated Annealing (SA). Sebanyak 18 run Genetic Algorithm (GA) masih belum memiliki data pengukuran. Satu run merujuk pada satu eksekusi algoritma untuk satu problem dengan satu seed.

4.1.1 Data Uji dan Lingkungan Eksperimen

Objektif utama adalah **`TOTAL_VALUE`**, yaitu jumlah nilai paket termuat tanpa pembobotan ETA. Dataset pengujian terdiri atas satu truk `truck-a` berukuran $10 \times 8 \times 6$ dan berkapasitas 100, serta sembilan paket pada Tabel 2 dengan atribut asli. Dataset yang sama digunakan untuk membandingkan hasil antaralgoritma, seed, dan konfigurasi.

ID	Dimensi (w, l, h)	Nilai	Berat	Rapuh	ETA
P01	$(4, 3, 2)$	40	20	Tidak	2
P02	$(3, 3, 2)$	30	15	Tidak	1
P03	$(2, 2, 1)$	25	5	Ya	0
P04	$(2, 4, 3)$	35	18	Tidak	3
P05	$(3, 2, 2)$	20	10	Tidak	4
P06	$(1, 1, 1)$	8	2	Ya	1
P07	$(5, 4, 3)$	50	30	Tidak	2
P08	$(6, 6, 6)$	60	40	Tidak	5
P09	$(2, 2, 2)$	12	6	Tidak	0

Tabel 2. Data paket pada dataset pengujian.

Jumlah nilai seluruh paket adalah 280, sehingga menjadi **batas atas objektif yang diketahui**, bukan nilai optimum yang telah dicapai. Pengujian difokuskan pada satu truk dengan batas kapasitas 100 kg.

4.1.2 Konfigurasi Parameter dan Pengulangan Eksperimen

Setiap konfigurasi memiliki **tiga pengulangan dengan seed 42, 123, dan 2026**. Rancangan utama mencakup empat varian HC masing-masing tiga run, tiga run SA, serta dua kelompok GA masing-masing sembilan run, sehingga jumlahnya **33 run per dataset**. Konfigurasi GA dengan populasi 50 dan 100 generasi muncul pada kedua kelompok dengan label berbeda; enam run itu tercakup dalam 18 run GA. Konfigurasi parameter setiap metode dirangkum pada Tabel 3.

Metrik pengujian meliputi skor objektif awal, akhir, dan terbaik, runtime, jumlah iterasi aktual, serta berat dan jumlah paket termuat pada state akhir. Skor terbaik dibedakan dari skor akhir karena solusi terakhir tidak selalu menjadi solusi terbaik sepanjang pencarian. Runtime mencakup inisialisasi dan pencarian, sedangkan validasi akhir, penyimpanan hasil, komunikasi HTTP, dan rendering tidak termasuk di dalamnya.

Metode	Konfigurasi	Run
HC steepest-ascent	Maksimum 2.000 iterasi, 50 kandidat per iterasi; tanpa sideways atau restart.	3
HC stochastic	Maksimum 2.000 iterasi, 50 kandidat per iterasi; pemilihan peningkat seragam.	3
HC sideways	Maksimum 2.000 iterasi, 50 kandidat per iterasi, maksimum 100 sideways berturut-turut.	3
HC random-restart	Maksimum 10 restart; 11 climb, masing-masing maksimum 2.000 iterasi dan 50 kandidat per iterasi.	3
SA	$T_0 = 30$, $\alpha = 0{,}995$, $T_{\min} = 0{,}001$, maksimum 5.000 iterasi, ambang stagnasi 50 iterasi.	3
GA: variasi generasi	Populasi tetap 50; generasi 50, 100, dan 200.	9
GA: variasi populasi	Generasi tetap 100; populasi 20, 50, dan 100.	9

Tabel 3. Kontrol dan jumlah run yang direncanakan.

4.2 Hasil Eksperimen dan Visualisasi Program

Pengujian mencakup empat varian HC dan SA dengan objektif Total value. Hasil setiap run meliputi skor awal, akhir, dan terbaik. Visualisasi menunjukkan susunan paket pada state akhir beserta jumlah paket dan berat muatannya. Grafik membandingkan skor dan runtime antaralgoritma.

4.2.1 Hill Climbing

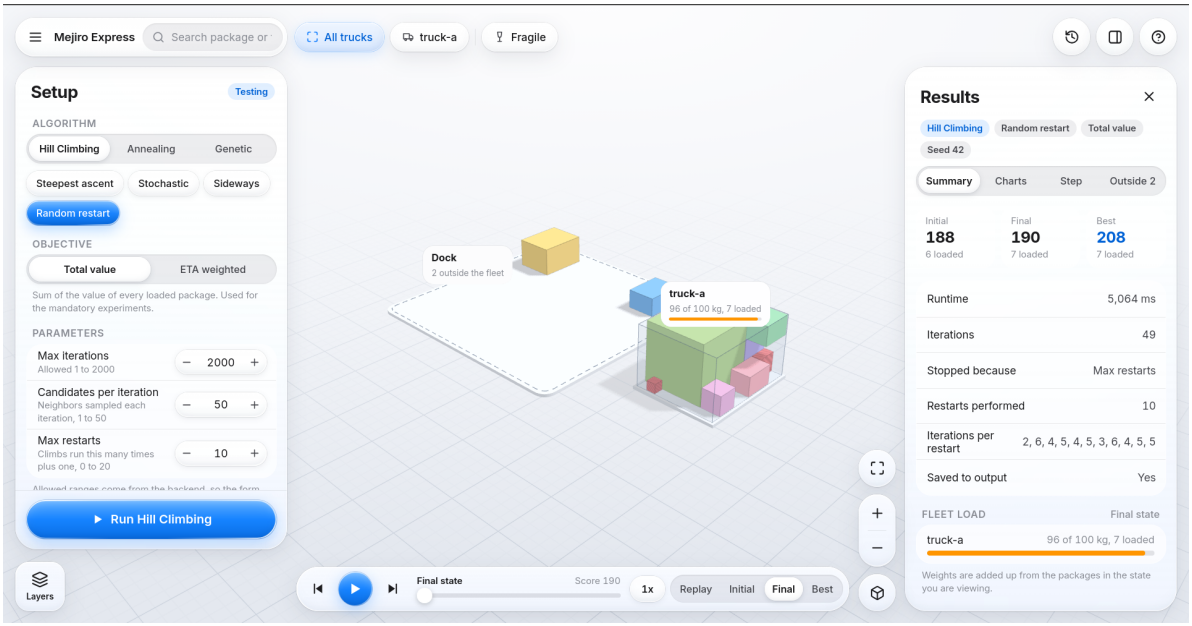
Metode	Seed	Awal	Akhir	Terbaik	ms	Iterasi	kg
Steepest-ascent	42	188	208	208	403	2	100
Steepest-ascent	123	68	170	170	632	5	76
Steepest-ascent	2026	93	208	208	488	4	100
Stochastic	42	188	208	208	370	2	100
Stochastic	123	68	170	170	653	5	76
Stochastic	2026	93	170	170	607	5	76
Sideways	42	188	208	208	16530	102	100
Sideways	123	68	208	208	16996	108	100
Sideways	2026	93	208	208	16100	104	100
Random-restart	42	188	190	208	5064	49	96
Random-restart	123	68	190	208	4135	42	91
Random-restart	2026	93	208	208	4794	42	100

Tabel 4. Hasil pengukuran manual 12 run HC. Kolom kg adalah berat muatan akhir; seluruh run berakhir dengan tujuh paket termuat.

Steepest-ascent dan stochastic berhenti dengan alasan *Local optimum* pada seluruh seed. Steepest-ascent menghasilkan skor akhir 208, 170, dan 208, sedangkan stochastic menghasilkan 208, 170, dan 170. Status tersebut berarti tidak ditemukan peningkatan pada kandidat yang diperiksa saat penghentian, sehingga tidak membuktikan optimum global.

Sideways mencapai skor akhir 208 pada ketiga seed dan berhenti karena *Max sideways*. Jumlah iterasi aktual 102, 108, dan 104 lebih kecil daripada batas 2.000 iterasi. Ringkasan UI mencatat jumlah sideways total 100, 101, dan 100; angka total ini perlu dibedakan dari batas 100 sideways berturut-turut pada konfigurasi.

Random-restart menjalankan 10 restart dan berhenti karena *Max restarts*. Skor terbaik selalu 208, tetapi skor akhir pada seed 42 dan 123 adalah 190. Selisih tersebut menunjukkan perlunya membedakan solusi terakhir dengan solusi terbaik sepanjang seluruh climb. Pada dua run tersebut berat muatan akhir masing-masing 96 kg dan 91 kg, meskipun nilai akhir sama. Ketiga seed tetap memuat tujuh paket pada state akhir.



Gambar 7. Random-restart seed 42: skor akhir 190, skor terbaik 208, 49 iterasi, dan 10 restart. Pilihan Final menampilkan muatan akhir 96 kg.

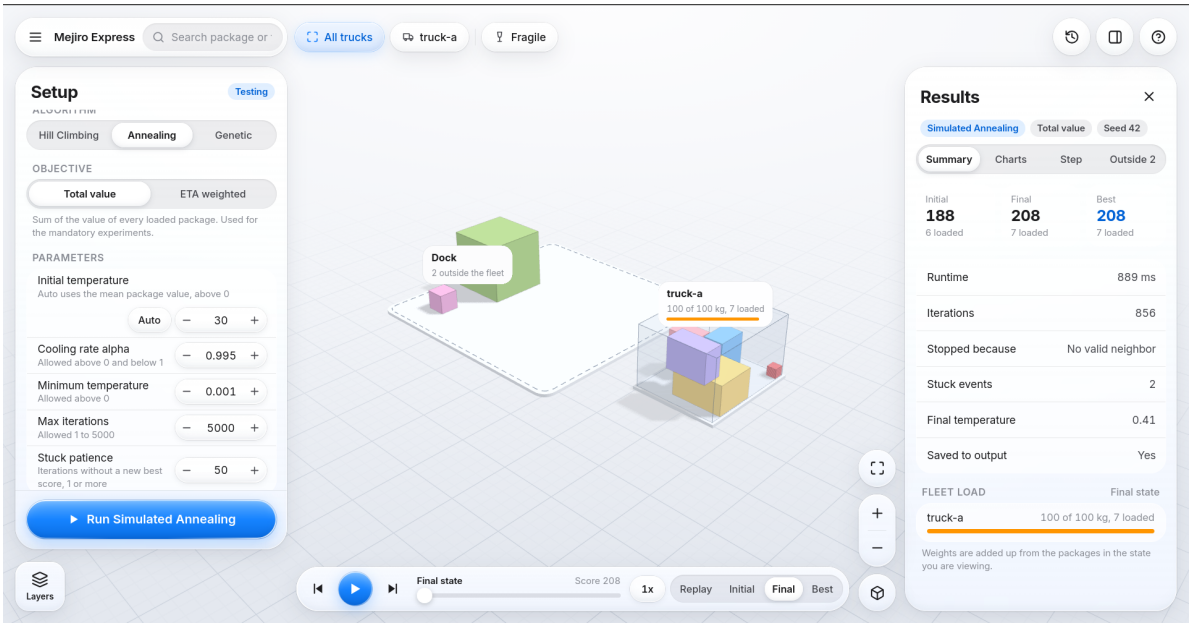
4.2.2 Simulated Annealing

Metode	Seed	Awal	Akhir	Terbaik	ms	Iterasi	kg
SA	42	188	208	208	889	856	100
SA	123	68	208	208	2014	2057	100
SA	2026	93	208	208	1998	2057	100

Tabel 5. Hasil pengukuran manual tiga run SA. Seluruh state akhir memuat tujuh paket.

SA mencapai skor akhir dan terbaik 208 pada seluruh seed. Seed 42 berhenti karena *No valid neighbor* setelah 856 iterasi, dengan suhu akhir yang ditampilkan 0,41. Seed 123 dan 2026 berhenti karena *Temperature minimum* setelah 2.057 iterasi, dengan suhu akhir ditampilkan 0,001. Jumlah *stuck events* masing-masing adalah 2, 2, dan 3; metrik ini bukan jumlah iterasi stagnasi berturut-turut. Penghentian aktual pada ketiga run terjadi sebelum batas 5.000 iterasi.

Konfigurasi SA menggunakan $T_0 = 30$, $\alpha = 0{,}995$, $T_{\min} = 0{,}001$, dan ambang stagnasi 50.



Gambar 8. SA seed 42: pengaturan parameter, state akhir, skor awal/akhir/terbaik, runtime, dan alasan penghentian.

4.2.3 Genetic Algorithm

Hasil 18 run GA belum tersedia. Subbagian ini dan tabel berikut memuat konfigurasi yang direncanakan; perbandingan hasil GA dengan HC dan SA belum dapat dilakukan.

Label kelompok	Populasi	Generasi	Seed
`generations`	50	50	42, 123, 2026
`generations`	50	100	42, 123, 2026
`generations`	50	200	42, 123, 2026
`population_size`	20	100	42, 123, 2026
`population_size`	50	100	42, 123, 2026
`population_size`	100	100	42, 123, 2026

Tabel 6. Enam konfigurasi GA yang direncanakan, masing-masing dengan tiga pengulangan.

4.3 Analisis Eksperimen

Seluruh ringkasan dihitung dari tiga seed per metode. Simpangan baku yang digunakan adalah simpangan baku populasi deskriptif, $\sigma = \sqrt{\sum_{i=1}^{3}(x_i - \bar{x})^2/3}$. Jumlah pengulangan ini terbatas dan tidak digunakan untuk menyatakan signifikansi statistik.

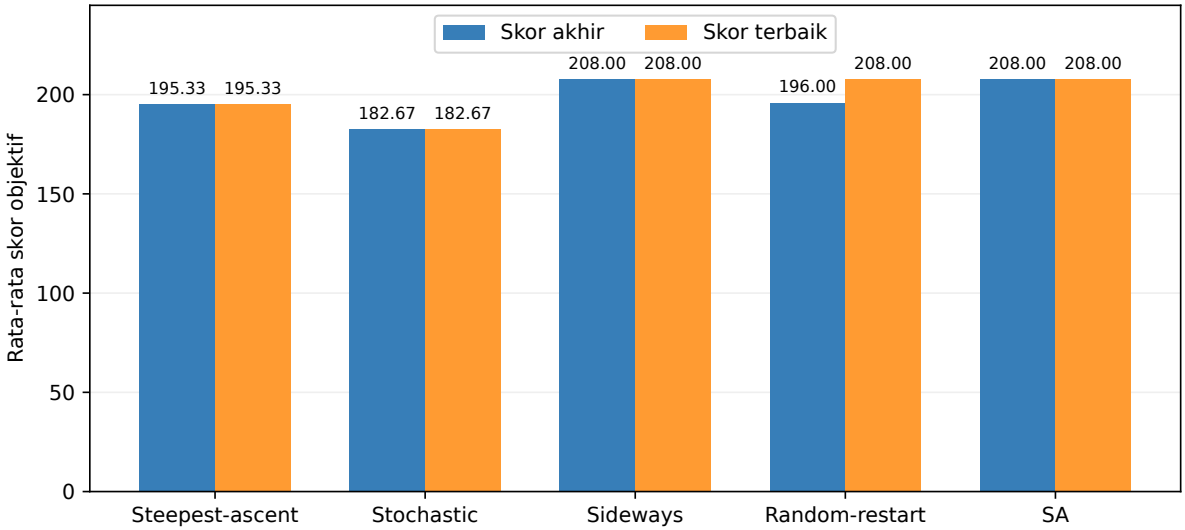
Metode	$\bar{f}_{akhir}$	σ_{akhir}	$\bar{f}_{terbaik}$	$\bar{t}$ (s)	$\bar{I}$
Steepest-ascent	195.33	17.91	195.33	0.508	3.67
Stochastic	182.67	17.91	182.67	0.543	4.00
Sideways	208.00	0.00	208.00	16.542	104.67
Random-restart	196.00	8.49	208.00	4.664	44.33
SA	208.00	0.00	208.00	1.634	1656.67

Tabel 7. Ringkasan deskriptif tiga seed per metode: rata-rata skor akhir, simpangan baku populasi skor akhir, rata-rata skor terbaik, runtime, dan iterasi aktual.

4.3.1 Perbandingan Kualitas Solusi

Sideways dan SA memiliki rata-rata skor akhir tertinggi, yaitu 208. Steepest-ascent memiliki rata-rata 195,33, random-restart 196,00, dan stochastic 182,67. Jika yang dibandingkan adalah skor terbaik sepanjang pencarian, random-restart juga mencapai 208 pada seluruh seed. Selisih rata-rata skor terbaik dan akhir random-restart sebesar 12 poin berasal dari dua run yang berakhir pada skor 190.

Skor maksimum teramati 208 setara dengan 74,29% dari jumlah nilai seluruh paket (280). Angka 280 adalah batas atas longgar yang mengabaikan kapasitas dan geometri, sehingga rasio tersebut tidak boleh ditafsirkan sebagai rasio terhadap optimum yang terbukti. Jumlah paket akhir sama-sama tujuh pada seluruh run, tetapi nilai dan berat akhir berbeda; jumlah paket saja tidak cukup untuk membandingkan kualitas objektif Total value.



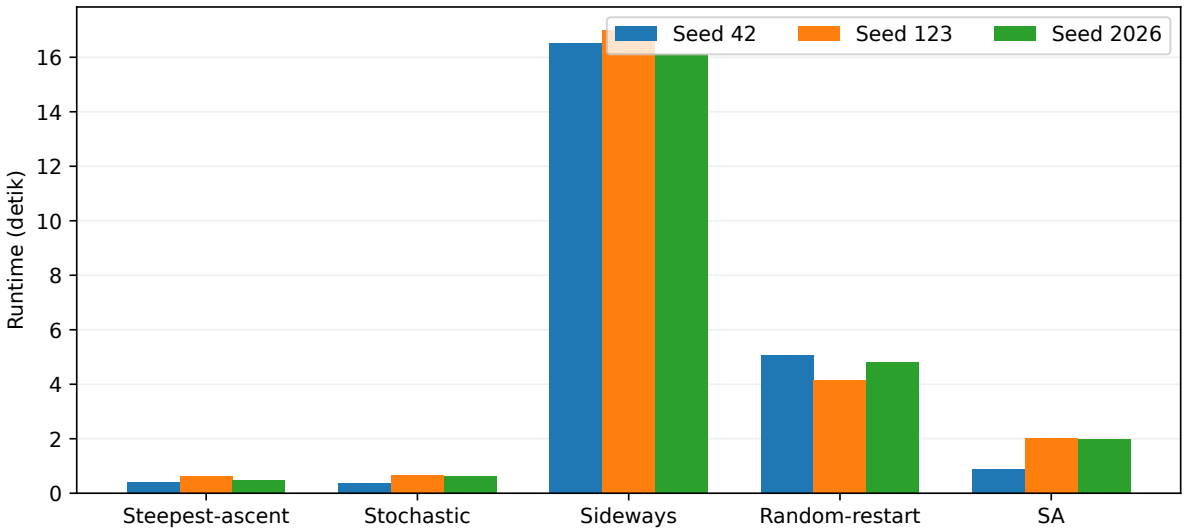
Gambar 9. Perbandingan rata-rata skor akhir dan terbaik berdasarkan tiga seed. Grafik ini merupakan agregasi hasil akhir, bukan grafik lintasan per iterasi.

4.3.2 Perbandingan Durasi Pencarian

Rata-rata runtime steepest-ascent dan stochastic masing-masing 0,508 detik dan 0,543 detik. SA membutuhkan rata-rata 1,634 detik, random-restart 4,664 detik, dan sideways 16,542 detik. Sideways mencapai skor akhir 208 pada semua seed, tetapi membutuhkan waktu lebih lama daripada SA pada pengukuran ini.

Jumlah iterasi antaralgoritma tidak langsung menunjukkan biaya komputasi yang setara. HC menggunakan hingga 50 kandidat per iterasi pada konfigurasi pengujian, sedan-

gkan satu langkah SA memiliki mekanisme sampling yang berbeda. Dengan demikian, 2.057 iterasi SA tidak otomatis lebih mahal daripada sekitar 100 iterasi sideways. Durasi yang dibandingkan adalah waktu komputasi aplikasi untuk inisialisasi dan pencarian.



Gambar 10. Runtime tercatat untuk setiap seed dan metode, dikonversi dari milidetik ke detik.

4.3.3 Konsistensi Hasil Eksperimen

Skor awal pada seed 42, 123, dan 2026 adalah 188, 68, dan 93 untuk seluruh metode yang diuji. Dengan skor awal yang sama pada setiap seed, perbedaan peningkatan skor dapat dibandingkan antaralgoritma. Kesamaan skor awal tidak dengan sendirinya menunjukkan kesamaan susunan paket.

Sideways dan SA memiliki simpangan baku skor akhir nol pada tiga seed ini. Steepest-ascent dan stochastic memiliki simpangan baku 17,91, sedangkan random-restart memiliki simpangan baku skor akhir 8,49. Jika yang dinilai skor terbaik, random-restart juga memiliki simpangan baku nol. Hasil tersebut menunjukkan konsistensi pada sampel yang diamati dan tidak menjamin perilaku yang sama untuk seed atau dataset lain.

4.3.4 Pengaruh Parameter Genetic Algorithm

Pengaruh variasi generasi dan populasi belum dapat dianalisis karena hasil 18 run GA belum tersedia. Tabel konfigurasi GA tetap menjadi acuan pengujian lanjutan. Analisis perlu membedakan kelompok variasi generasi dan variasi populasi, termasuk konfigurasi populasi 50 dan generasi 100 yang muncul di kedua kelompok.

5 Kesimpulan dan Saran

5.1 Kesimpulan

5.2 Saran

6 Pembagian Tugas Tiap Anggota Kelompok

Nama Lengkap	NIM	Tugas/Kontribusi
Samuelson Dharmawan Tanuraharja	13524001	
Nicholas Wise Saragih Sumbayak	13524037	
Neswa Eka Anggara	13524136	

Tabel 8. Pembagian tugas anggota kelompok

Daftar Pustaka

[1] Tim Asisten Laboratorium Inteligensi Artifisial, "Spesifikasi Tugas Besar 1 IF3170 Inteligensi Artifisial 2026/2027," ver. 1.4, Institut Teknologi Bandung, Bandung, Indonesia, Sep. 2026.

[2] S. J. Russell and P. Norvig, *Artificial Intelligence: A Modern Approach*, 4th ed. Hoboken, NJ, USA: Pearson, 2021.

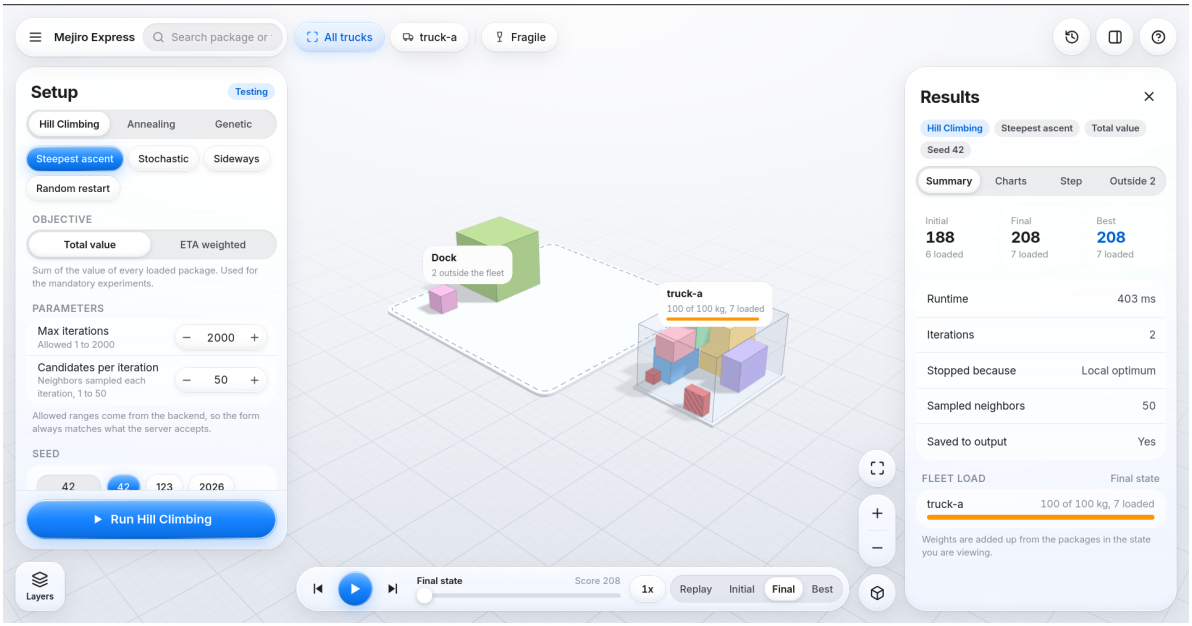
[3] Tim Pengajar IF3170 Inteligensi Artifisial, "Beyond Classical Search," lecture slides, Institut Teknologi Bandung, Bandung, Indonesia, 2026.

A Form Penggunaan Generative AI

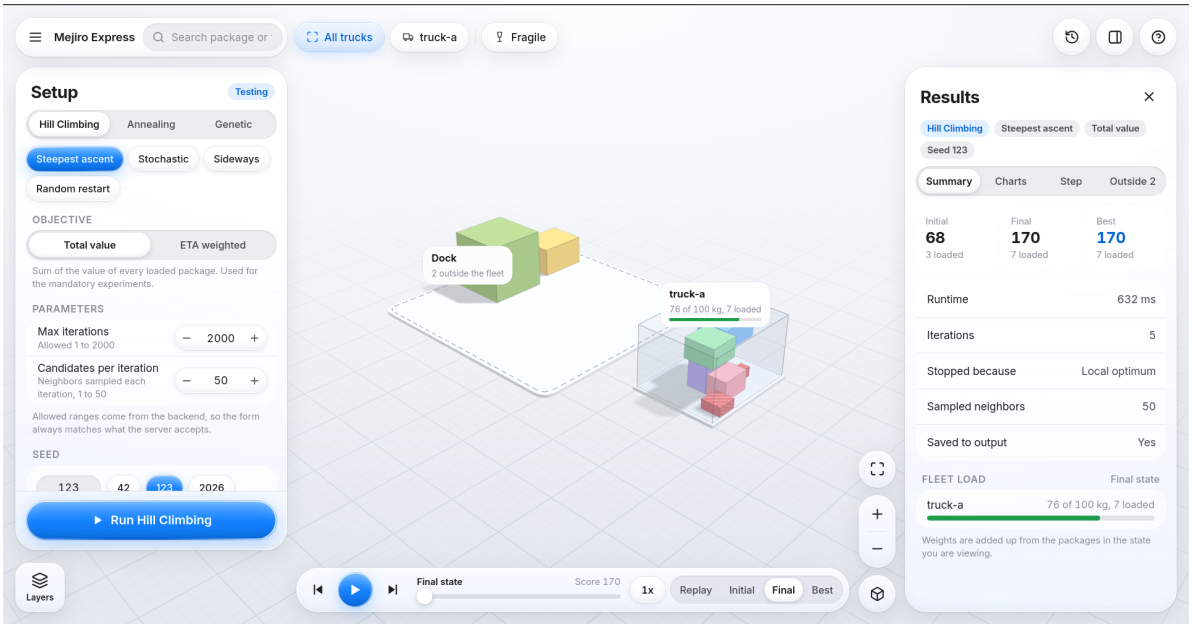
B Lampiran Lainnya (Bila Ada)

C Bukti Pengujian Manual

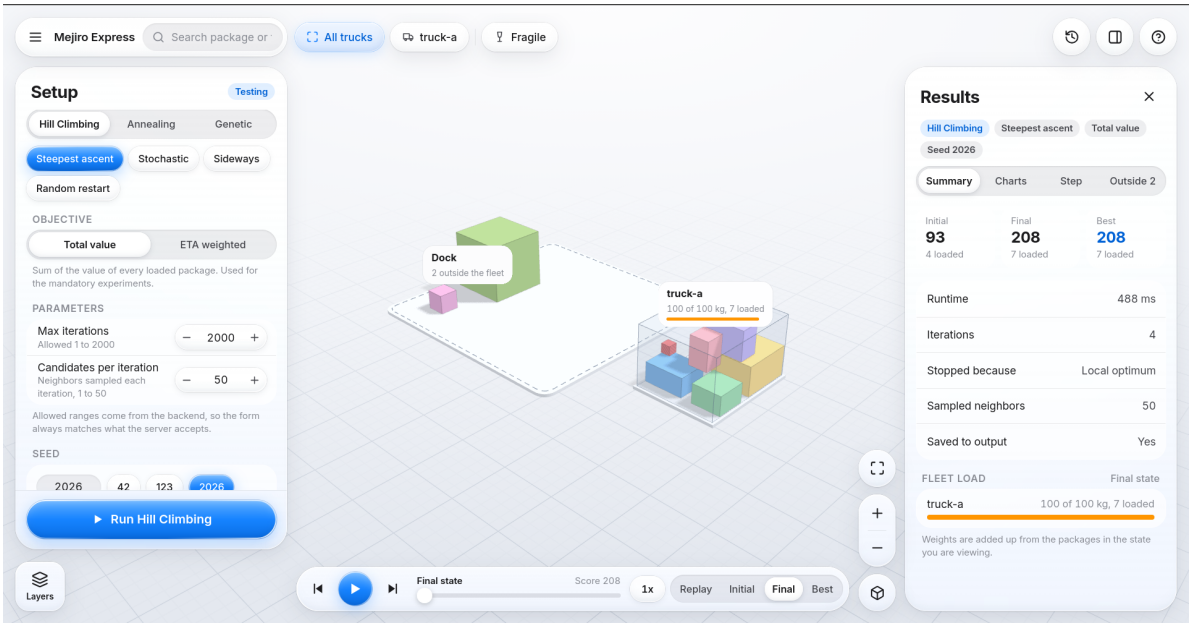
Tangkapan layar berikut memperlihatkan state akhir, skor objektif, runtime, dan jumlah iterasi setiap run, melengkapi Gambar 7 dan Gambar 8.



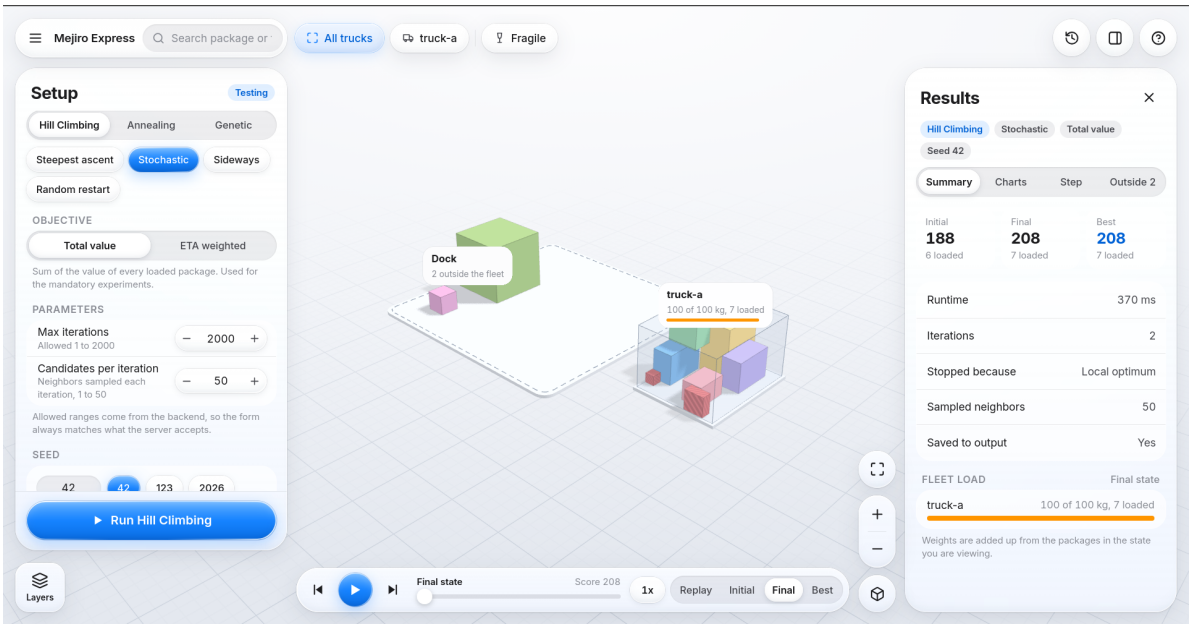
Gambar 11. Bukti Steepest-ascent seed 42: skor akhir 208, skor terbaik 208, runtime 403 ms, dan 2 iterasi.



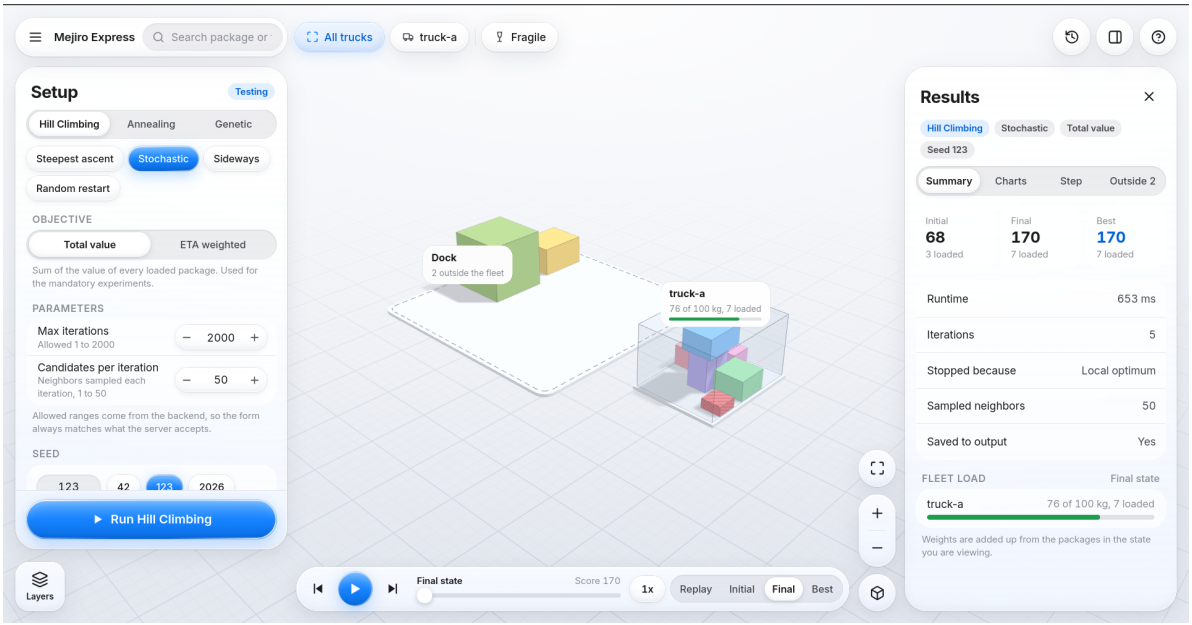
Gambar 12. Bukti Steepest-ascent seed 123: skor akhir 170, skor terbaik 170, runtime 632 ms, dan 5 iterasi.



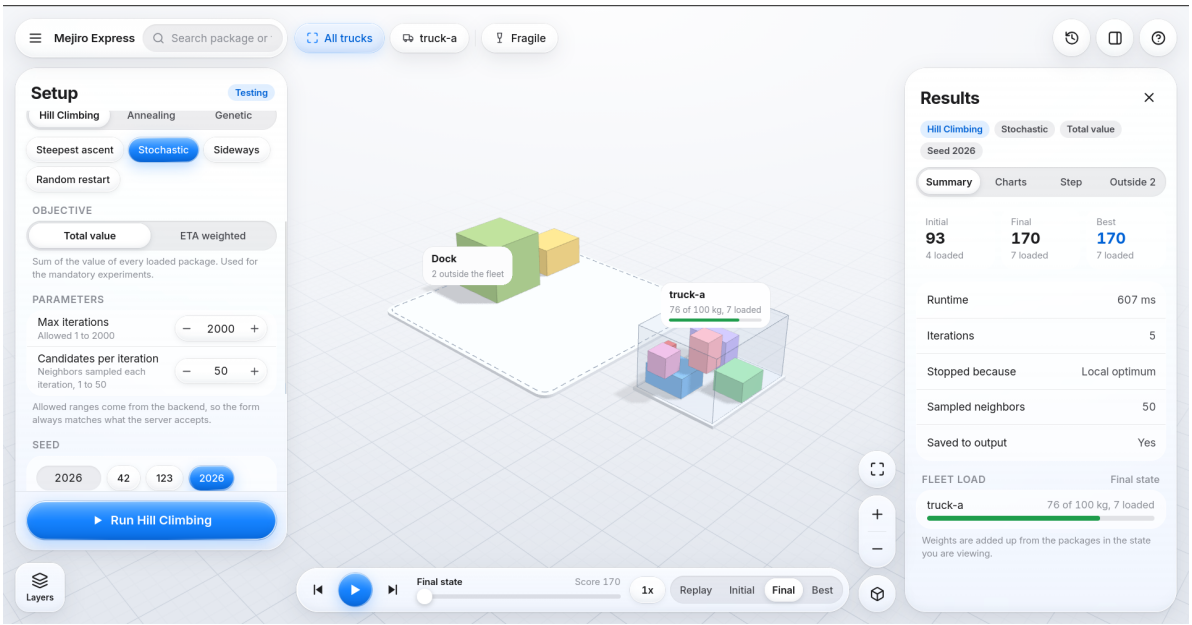
Gambar 13. Bukti Steepest-ascent seed 2026: skor akhir 208, skor terbaik 208, runtime 488 ms, dan 4 iterasi.



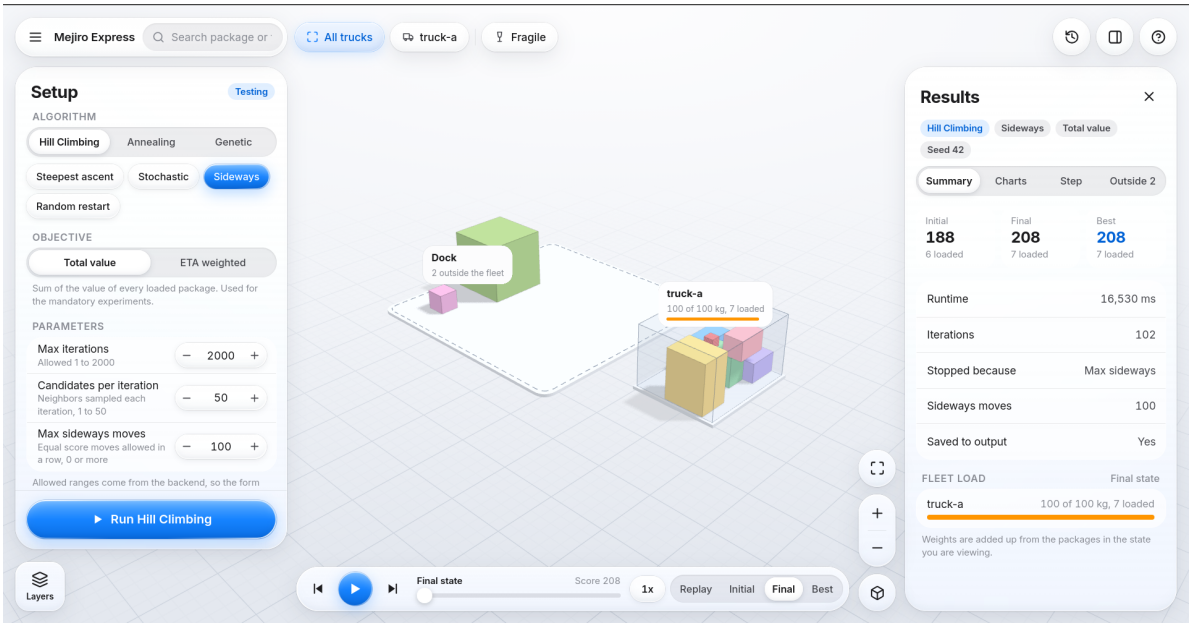
Gambar 14. Bukti Stochastic seed 42: skor akhir 208, skor terbaik 208, runtime 370 ms, dan 2 iterasi.



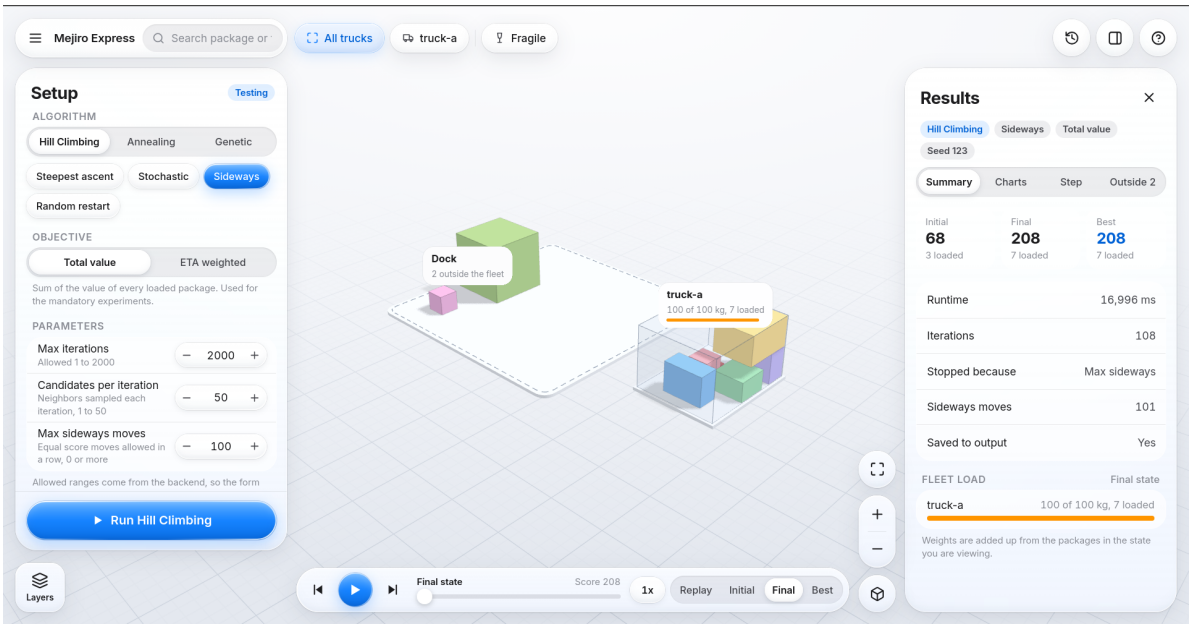
Gambar 15. Bukti Stochastic seed 123: skor akhir 170, skor terbaik 170, runtime 653 ms, dan 5 iterasi.



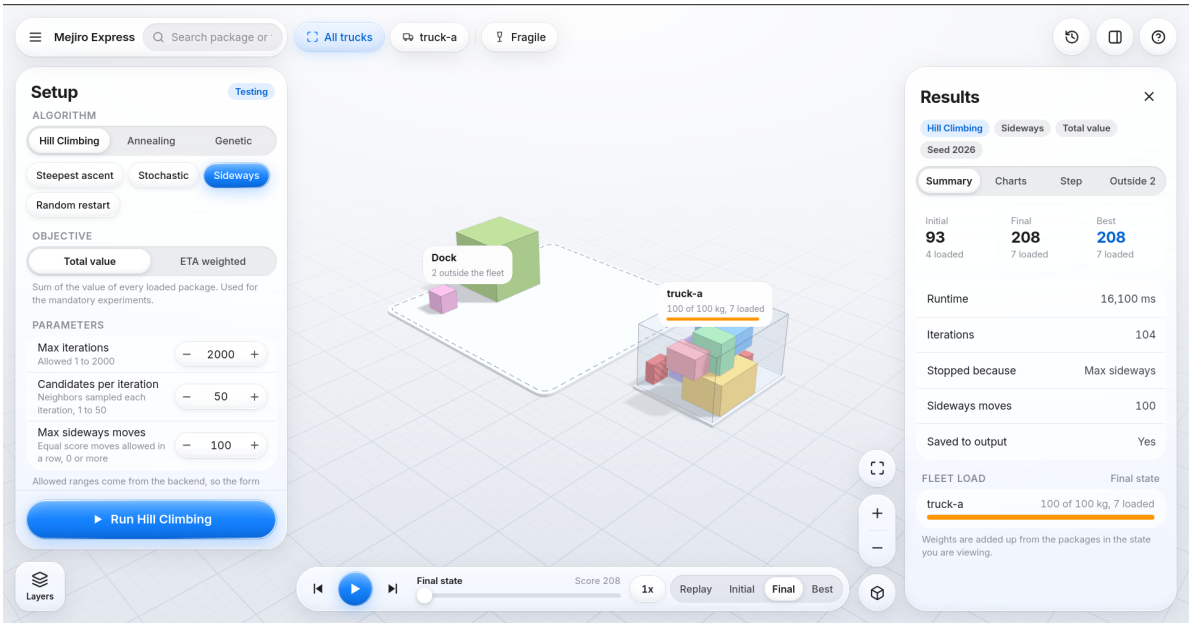
Gambar 16. Bukti Stochastic seed 2026: skor akhir 170, skor terbaik 170, runtime 607 ms, dan 5 iterasi.



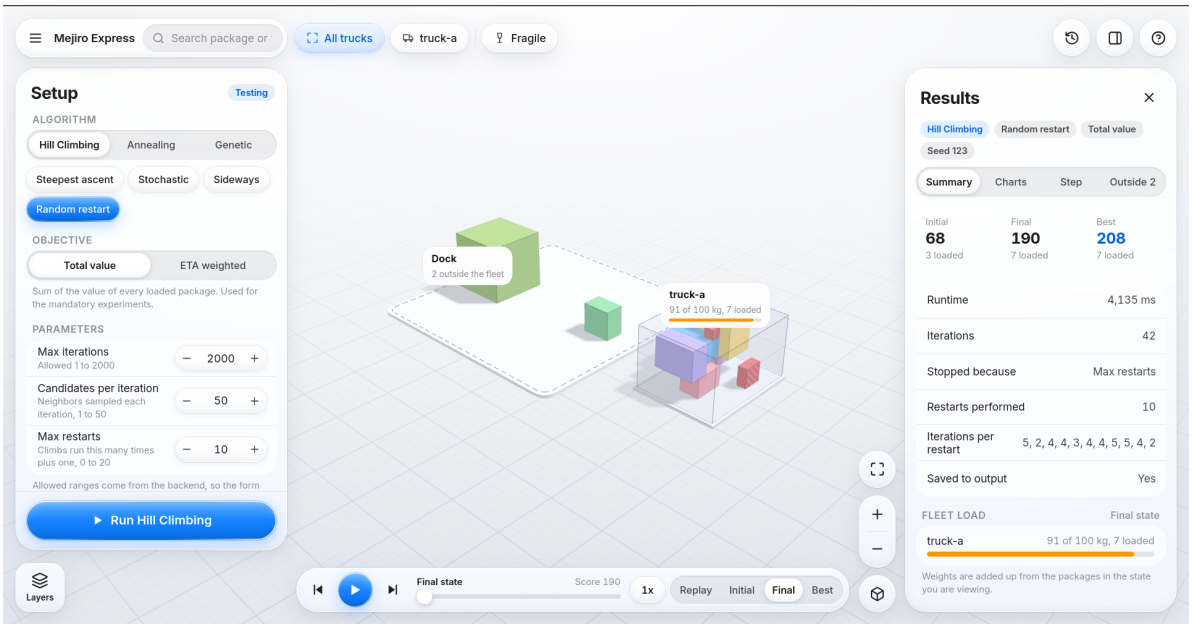
Gambar 17. Bukti Sideways seed 42: skor akhir 208, skor terbaik 208, runtime 16530 ms, dan 102 iterasi.



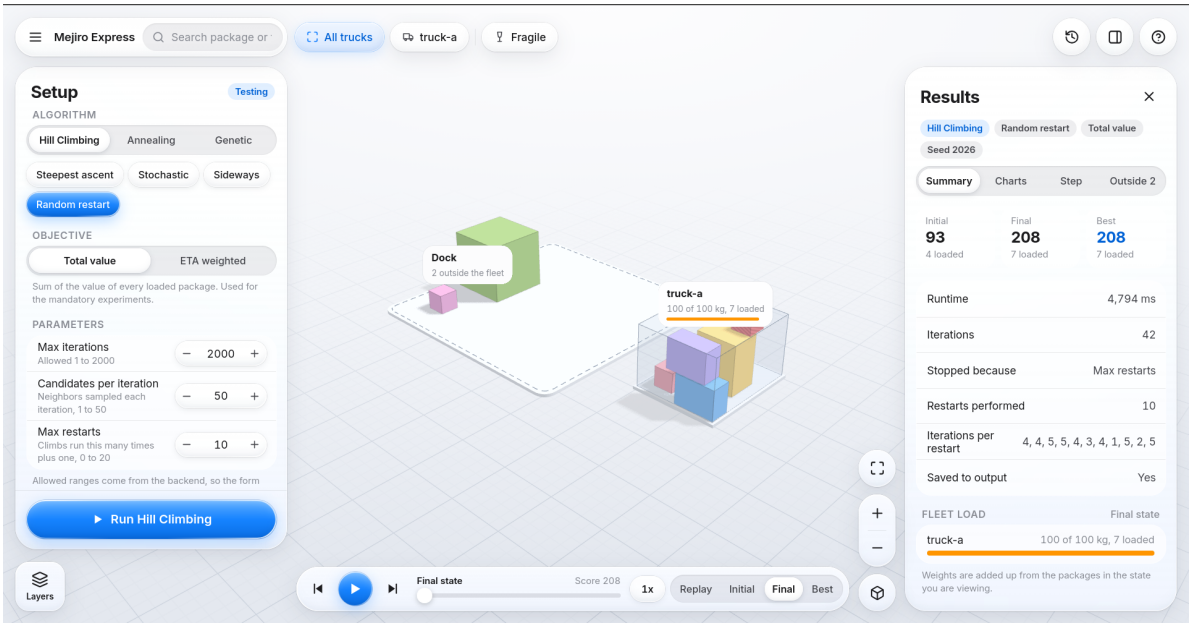
Gambar 18. Bukti Sideways seed 123: skor akhir 208, skor terbaik 208, runtime 16996 ms, dan 108 iterasi.



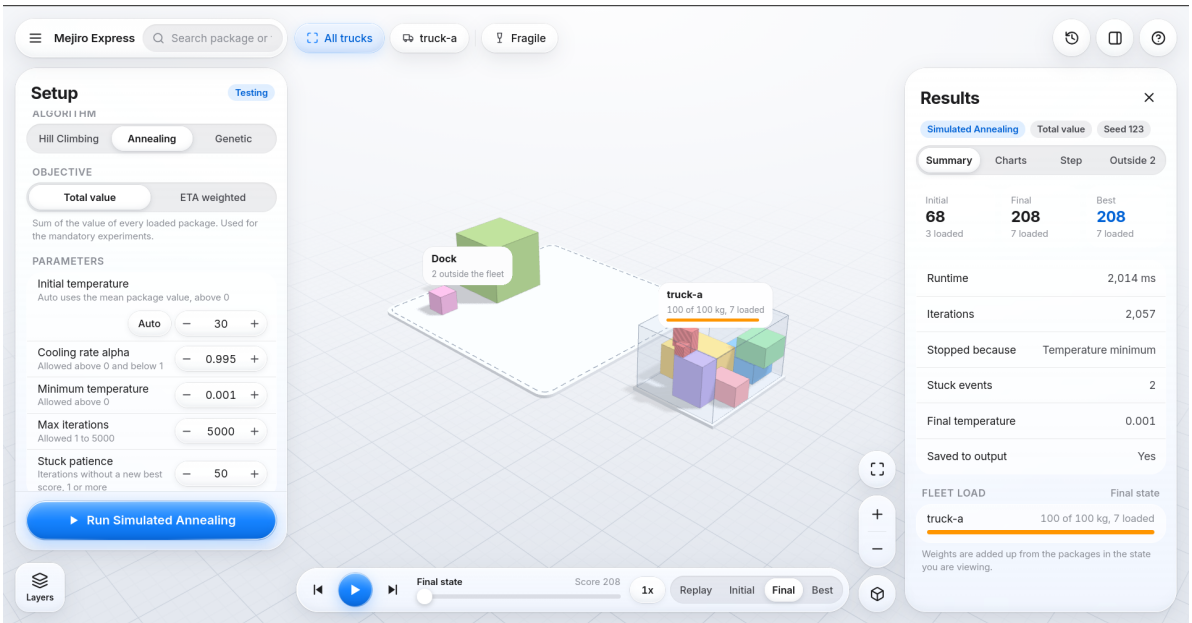
Gambar 19. Bukti Sideways seed 2026: skor akhir 208, skor terbaik 208, runtime 16100 ms, dan 104 iterasi.



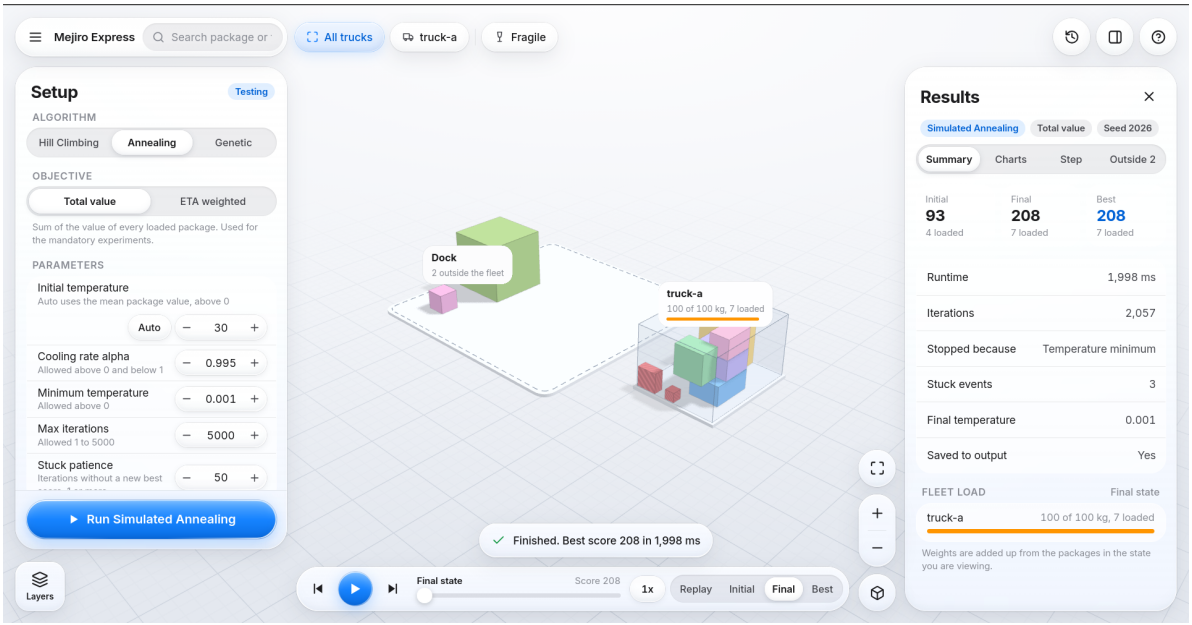
Gambar 20. Bukti Random-restart seed 123: skor akhir 190, skor terbaik 208, runtime 4135 ms, dan 42 iterasi.



Gambar 21. Bukti Random-restart seed 2026: skor akhir 208, skor terbaik 208, runtime 4794 ms, dan 42 iterasi.



Gambar 22. Bukti SA seed 123: skor akhir 208, skor terbaik 208, runtime 2014 ms, dan 2057 iterasi.



Gambar 23. Bukti SA seed 2026: skor akhir 208, skor terbaik 208, runtime 1998 ms, dan 2057 iterasi.